



PROPOSAL TUGAS AKHIR - EF234702

**PENDEKATAN *NAMED-ENTITY RECOGNITION*
DALAM PENGEMBANGAN *KNOWLEDGE GRAPH* SIRAH
NABAWIYAH**

GENTA PUTRA PRAYOGA

NRP 5025221040

Dosen Pembimbing

Dini Adni Navastara, S.Kom., M.Sc.

NIP 198510172015042001

Dosen Ko-pembimbing

Ratih Nur Esti Anggraini, S.Kom, M.Sc., Ph.D.

NIP 198412102014042003

Program Studi S-1 Teknik Informatika

Departemen Teknik Informatika

Fakultas Teknologi Elektro dan Informatika Cerdas

Institut Teknologi Sepuluh Nopember

Surabaya

2026

Halaman ini sengaja dikosongkan

LEMBAR PENGESAHAN

PENDEKATAN *NAMED-ENTITY RECOGNITION* DALAM PEMBANGUNAN *KNOWLEDGE GRAPH* SIRAH NABAWIYAH

PROPOSAL TUGAS AKHIR

Diajukan untuk memenuhi salah satu syarat
memperoleh gelar Sarjana Komputer pada
Program Studi S-1 Teknik Informatika
Departemen Teknik Informatika
Fakultas Teknologi Elektro dan Informatika Cerdas
Institut Teknologi Sepuluh Nopember

Oleh: **GENTA PUTRA PRAYOGA**

NRP. 5025221040

Disetujui oleh Tim Penguji Proposal Tugas Akhir:

- | | |
|--|---------------|
| 1. Dini Adni Navastara, S.Kom., M.Sc. | Pembimbing |
| 2. Ratih Nur Esti Anggraini, S.Kom, M.Sc., Ph.D. | Ko-pembimbing |
| 3. <Nama dan gelar penguji> | Penguji |
| 4. <Nama dan gelar penguji> | Penguji |

SURABAYA

Januari, 2026

Halaman ini sengaja dikosongkan.

APPROVAL SHEET

NAMED-ENTITY RECOGNITION–BASED CONSTRUCTION OF A SIRAH NABAWIYAH KNOWLEDGE GRAPH

FINAL PROJECT PROPOSAL

Submitted to fulfill one of the requirements
for obtaining a Bachelor of Computer Science degree at
Undergraduate Study Program of Informatics
Department of Informatics
Faculty of Intelligent Electrical and Informatics Technology
Institut Teknologi Sepuluh Nopember

By: **GENTA PUTRA PRAYOGA**

NRP. 5025221040

Approved by Final Project Proposal Examiner Team:

- | | |
|--|------------|
| 1. Dini Adni Navastara, S.Kom., M.Sc. | Advisor |
| 2. Ratih Nur Esti Anggraini, S.Kom, M.Sc., Ph.D. | Co-advisor |
| 3. <Name and title> | Examiner 1 |
| 4. <Name and title> | Examiner 2 |

SURABAYA

January, 2026

This page is intentionally left blank.

ABSTRAK

PENDEKATAN *NAMED-ENTITY RECOGNITION* DALAM PEMBANGUNAN *KNOWLEDGE GRAPH* SIRAH NABAWIYAH

Nama Mahasiswa / NRP : Genta Putra Prayoga / 5025221040
Departemen : Teknik Informatika FTEIC - ITS
Dosen Pembimbing : Dini Adni Navastara, S.Kom., M.Sc.
Dosen Ko-pembimbing : Ratih Nur Esti Anggraini, S.Kom, M.Sc., Ph.D.

Abstrak

Sirah Nabawiyah atau biografi Nabi Muhammad SAW merupakan catatan sejarah yang memuat narasi kehidupan Rasulullah beserta konteks sosial, peristiwa penting, tokoh yang terlibat, lokasi kejadian, dan rentang waktu dalam sejarah Islam awal. Sebagai sumber pembelajaran nilai, akhlak, dan keteladanan, Sirah menjadi rujukan penting dalam kajian keislaman. Namun, penyajiannya dalam bentuk teks naratif panjang menyebabkan penelusuran informasi relasional, seperti mengidentifikasi tokoh yang terlibat dalam peristiwa tertentu atau urutan kronologis kejadian menjadi kurang efisien. Penelitian ini bertujuan mengonstruksi basis data graf Sirah Nabawiyah berbasis *Named-Entity Recognition* menggunakan Neo4j untuk merepresentasikan pengetahuan sebagai *node* dan *relationship* yang eksplisit. Data bersumber dari dokumen Sirah berbahasa Indonesia yang dikonversi menggunakan PaddleOCR, kemudian melalui prapemrosesan untuk membersihkan *noise* OCR. Ekstraksi informasi dilakukan melalui dua skenario: *SRL-based* NER yang memanfaatkan Semantic Role Labeling, dan *LLM-based* NER yang mengekstraksi entitas melalui *prompting* terstruktur. Entitas dimodelkan sebagai *node* dengan label *Person*, *Event*, *Location*, dan *Time*, sedangkan relasi dibentuk sebagai *relationship* bertipe *INVOLVED_IN*, *OCCURRED_AT*, dan *OCCURRED_ON*. Evaluasi dilakukan terhadap hasil NER menggunakan metrik *Precision*, *Recall*, dan *F1-score*, serta evaluasi fungsional graf melalui eksekusi kueri *Cypher*. Luaran penelitian berupa basis data graf operasional dalam Neo4j yang dapat menjadi fondasi penelusuran informasi berbasis relasi pada kajian Sirah Nabawiyah.

Kata kunci: Sirah Nabawiyah, *Knowledge Graph*, *Neo4j*, *Named-Entity Recognition*, *Graph Database*.

Halaman ini sengaja dikosongkan.

ABSTRACT

NAMED-ENTITY RECOGNITION-BASED CONSTRUCTION OF A SIRAH NABAWIYAH KNOWLEDGE GRAPH

Full Name / Student ID : Genta Putra Prayoga / 5025221040
Department : Informatics ELECTICS - ITS
Advisor : Dini Adni Navastara, S.Kom., M.Sc.
Co-advisor : Ratih Nur Esti Anggraini, S.Kom, M.Sc., Ph.D.

Abstract

Sirah Nabawiyah, or the biography of Prophet Muhammad (peace be upon him), constitutes a historical record documenting the life of the Prophet along with social contexts, significant events, involved figures, locations, and timeframes in early Islamic history. As a source for learning values, ethics, and exemplary conduct, Sirah serves as an important reference in Islamic studies. However, its presentation in long narrative text renders relational information seeking—such as identifying figures involved in specific events or chronological sequences—inefficient. This study aims to construct a Sirah Nabawiyah graph database based on Named Entity Recognition using Neo4j to represent knowledge as explicit nodes and relationships. Data are sourced from an Indonesian Sirah document converted using PaddleOCR, followed by preprocessing to clean OCR noise. Information extraction employs two scenarios: SRL-based NER leveraging Semantic Role Labeling, and LLM-based NER extracting entities through structured prompting. Entities are modeled as nodes with labels Person, Event, Location, and Time, while relations are formed as relationships typed INVOLVED_IN, OCCURRED_AT, and OCCURRED_ON. Evaluation assesses NER results using Precision, Recall, and F1-score metrics, alongside functional graph evaluation through Cypher query execution. Research outputs comprise an operational graph database in Neo4j serving as a foundation for relation-based information exploration in Sirah Nabawiyah studies.

Keywords: Sirah Nabawiyah, *Knowledge Graph*, *Neo4j*, *Named-Entity Recognition*, *Graph Database*.

This page is intentionally left blank.

DAFTAR ISI

LEMBAR PENGESAHAN.....	i
APPROVAL SHEET	iii
ABSTRAK.....	v
ABSTRACT.....	vii
DAFTAR ISI.....	ix
DAFTAR GAMBAR	xii
DAFTAR TABEL	xiv
DAFTAR KODE SUMBER	xvi
BAB 1 PENDAHULUAN	1
1.1 Latar Belakang.....	1
1.2 Rumusan Masalah.....	2
1.3 Batasan Masalah	2
1.4 Tujuan.....	3
1.5 Manfaat.....	3
1.5.1 Manfaat Teoritis	3
1.5.2 Manfaat Praktis.....	3
1.5.3 Manfaat Sosial	3
BAB 2 TINJAUAN PUSTAKA.....	5
2.1 Hasil Penelitian Terdahulu	5
2.2 Dasar Teori	10
2.2.1 Sirah Nabawiyah.....	10
2.2.2 <i>Optical Character Recognition</i>	11
2.2.3 <i>Named-Entity Recognition</i>	12
2.2.4 <i>Knowledge Graph</i>	14
2.2.5 Neo4j	15
2.2.6 Ekstraksi Relasi	16
2.2.7 Evaluasi	17
BAB 3 METODOLOGI.....	21
3.1 Metode dan Alur Kerja	21
3.1.1 Preparasi Dataset	21
3.1.2 <i>Preprocessing</i> Data.....	24
3.1.3 Chunking	25
3.1.4 Manual Labelling.....	25

3.1.5	Pseudo-labelling berbasis NER	26
3.1.6	Pembentukan Relasi	27
3.1.7	Konstruksi Knowledge Graph di Neo4j	28
3.1.8	Pengujian dan Evaluasi.....	29
3.2	Spesifikasi Lingkungan	31
3.2.1	Perangkat Keras	32
3.2.2	Perangkat Lunak.....	32
3.3	Rencana Implementasi.....	32
3.3.1	Implementasi Pseudo-labelling menggunakan SRL-Based NER.....	32
3.3.2	Implementasi Pembentukan Knowledge Graph Menggunakan Neo4j.....	35
3.4	Urutan Pelaksanaan Penelitian	38
DAFTAR PUSTAKA		39
LAMPIRAN.....		43

Halaman ini sengaja dikosongkan.

DAFTAR GAMBAR

Gambar 2.1 Contoh Hasil Penerapan NER pada Teks Bahasa Inggris (Vyas, 2018)	13
Gambar 2.2 Alur Pengerjaan PromptNER	14
Gambar 2.3 Contoh Penerapan Entitas dan Relasi dalam Knowledge Graph (Ji et al., 2021). 15	
Gambar 2.4 Contoh Implementasi Neo4j (Chaudhary et al., 2024).....	16
Gambar 3.1 Diagram Alir Sistem	21
Gambar 3.2 Diagram Alir Tahpan Preparasi Dataset	22
Gambar 3.3 Diagram Alir Tahapan Preprocessing Data	24
Gambar 3.4 Diagram Alir Tahapan Chunking	25
Gambar 3.5 Diagram Alir Tahapan Manual Labelling.....	26
Gambar 3.6 Diagram Alir Tahapan Pseudo-labelling NER dengan 2 Skenario	27
Gambar 3.7 Diagram Alir Tahapan Pembentukan Relasi	28
Gambar 3.8 Diagram Alir Pembuatan Knowledge Graph menggunakan Neo4j	28

Halaman ini sengaja dikosongkan.

DAFTAR TABEL

Tabel 2.1 Ringkasan Penelitian Terdahulu.....	7
Tabel 2.2 Contoh Daftar Label NER.....	12
Tabel 3.1 Hasil OCR Sirah Nabawiyah.....	22
Tabel 3.2 Struktur Dataset Sirah Nabawiyah	23
Tabel 3.3 Ringkasan Desain Evaluasi	29
Tabel 3.4 Lini Masa Pengerjaan Tugas Akhir	38

Halaman ini sengaja dikosongkan.

DAFTAR KODE SUMBER

Kode Semu 3.1 Alur Kerja SRL NER.....	34
Kode Semu 3.2 Alur Pembentukan Graph Databse menggunakan Neo4j	37

Halaman ini sengaja dikosongkan.

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Sirah Nabawiyah memiliki peran penting dalam pengetahuan Islam, tidak hanya sebagai catatan sejarah tentang kehidupan Nabi Muhammad SAW, tetapi juga sebagai dasar untuk memahami konteks turunnya wahyu, strategi dakwah, serta rujukan dalam pembelajaran nilai, akhlak, keteladanan, dan kepemimpinan dalam Islam (Abror & Rahma, 2024; Kusumah et al., 2022). Dalam kajian akademik, Sirah juga dipandang sebagai sumber historiografi yang kaya karena memuat keterkaitan antara praktik ritual, interaksi sosial, nilai moral, dan data historis, termasuk informasi tentang tokoh, peristiwa, lokasi, dan waktu dalam sejarah awal Islam (Abror & Rahma, 2024; Pratama, 2022). Namun, karena informasi Sirah umumnya disajikan sebagai narasi panjang yang tersusun kronologis, pembaca—baik akademisi maupun masyarakat umum—sering perlu menelusuri teks secara menyeluruh ketika ingin menemukan informasi tertentu atau membandingkan gaya penulisan, kecenderungan interpretasi, dan pemilihan sumber pada karya Sirah modern maupun klasik (Pratama, 2022).

Dalam praktiknya, kebutuhan pencarian informasi pada Sirah tidak hanya berupa menemukan bagian teks yang membahas suatu topik, tetapi juga menjawab pertanyaan spesifik seperti “tokoh yang terlibat dalam suatu peristiwa”, “peristiwa apa saja yang terjadi di suatu lokasi”, atau “bagaimana urutan kejadian berdasarkan waktu”. Tantangan ini sejalan dengan permasalahan klasik pada *Information Retrieval* (IR), yaitu adanya ketidaksesuaian antara istilah pada query pengguna dengan istilah yang muncul pada dokumen (*vocabulary mismatch*), hal ini membuat hasil pencarian berbasis dokumen tidak selalu tepat atau lengkap (Hambarde & Proenca, 2023). Kondisi menjadi semakin menantang ketika dokumen yang ditelusuri berukuran panjang, karena pengguna perlu melakukan sintesis informasi dari teks yang kompleks sehingga membutuhkan waktu dan usaha yang besar. Oleh karena itu, berbagai pendekatan bar uteris dikembangkan untuk membantu memahami dokumen panjang secara lebih efisien (Gana et al., 2025).

Permasalahan pencarian pada Sirah Nabawiyah juga dipengaruhi oleh karakteristik pengetahuannya yang relasional, yaitu keterkaitan erat antara tokoh–peristiwa–lokasi–waktu. Representasi berbasis dokumen (teks biasa) cenderung kurang efektif untuk menjawab kebutuhan eksplorasi hubungan, karena relasi antar informasi tidak tersimpan secara eksplisit. Sebagai alternatif, *knowledge graph* dapat dipahami sebagai graf semantik yang merepresentasikan pengetahuan dunia nyata melalui node dan edge, di mana unit informasi minimalnya dapat dinyatakan sebagai *knowledge tuple* (dua node yang dihubungkan oleh sebuah relasi) (Zhong et al., 2024). Selain itu, *knowledge graph* menekankan representasi eksplisit terhadap entitas dan relasi beserta informasi semantiknya, sehingga dukungan pengetahuan menjadi lebih terstruktur untuk kebutuhan penelusuran berbasis hubungan (Ren et al., 2024). Implementasinya dapat disimpan dan dikelola pada graph database, seperti Neo4j agar relasi antar entitas/peristiwa dapat ditelusuri secara lebih natural melalui query graph untuk mendukung pencarian informasi yang kontekstual (Ren et al., 2024; Zhong et al., 2024).

Untuk membangun basis data graf dari teks Sirah, dibutuhkan proses *information extraction* untuk mengubah teks tidak terstruktur menjadi struktur pengetahuan yang dapat dimodelkan sebagai graf. Tahap kunci dalam proses ini adalah *Named-Entity Recognition*

(NER) untuk mengekstraksi entitas seperti *Person*, *Location*, dan *Time*, serta pengenalan *Event* sebagai pusat keterhubungan narasi. Selanjutnya, hubungan antar entitas/event dibentuk melalui ekstraksi relasi sehingga menghasilkan *named-entity relationship* yang menjadi edge pada graf. Pendekatan konstruksi *knowledge graph* berbasis Neo4j telah diterapkan pada berbagai domain, misalnya pada pembangunan *knowledge graph* pengobatan tradisional yang memanfaatkan NER (BERT–CRF disertai peninjauan manual) dan menyediakan penelusuran melalui *Cypher query* (Xie et al., 2023). Selain itu, penelitian lain juga memandang konstruksi *knowledge graph* sebagai rangkaian proses yang mencakup pemodelan pengetahuan, ekstraksi entitas dan relasi, fusi, hingga penyimpanan, di mana Neo4j digunakan sebagai media penyimpanan agar hubungan antar pengetahuan dapat diakses melalui penelusuran berbasis graf (He et al., 2022). Dengan demikian, pipeline ekstraksi entitas–relasi dari teks menjadi landasan yang relevan untuk mengonstruksi basis data graf Sirah Nabawiyah menggunakan Neo4j.

Berdasarkan uraian tersebut, penelitian ini berfokus pada konstruksi Basis Data Graf Sirah Nabawiyah menggunakan Neo4j, dengan minimal empat label utama, yaitu *Person*, *Event*, *Location*, dan *Time*. Entitas dan peristiwa diekstraksi dari teks Sirah Nabawiyah berbahasa Indonesia menggunakan pendekatan *Named Entity Recognition* (NER), kemudian dimodelkan sebagai node dan dihubungkan melalui relasi untuk menghasilkan graf yang terstruktur. Evaluasi penelitian dilakukan secara terbatas pada evaluasi struktural berbasis similarity, yakni membandingkan konsistensi struktur graf (himpunan node dan relationship) yang dihasilkan dari dua skenario ekstraksi, yakni *SRL-based NER* dan *LLM-based NER*. Selain itu, kegunaan graf diverifikasi melalui eksekusi contoh kueri Cypher yang merepresentasikan kebutuhan penelusuran relasional pada Sirah Nabawiyah.

1.2 Rumusan Masalah

Berdasarkan latar belakang permasalahan yang telah diuraikan sebelumnya, penelitian ini diarahkan untuk mengkaji proses konstruksi basis data graf Sirah Nabawiyah secara sistematis, mulai dari tahap penyiapan data teks hingga evaluasi terbatas terhadap hasil ekstraksi dan struktur graf yang dibangun. Untuk itu, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana menyiapkan data teks Sirah Nabawiyah agar menjadi dataset yang siap digunakan?
2. Bagaimana melakukan ekstraksi entitas dari teks Sirah Nabawiyah menggunakan *Named Entity Recognition* (NER)?
3. Bagaimana merancang skema basis data graf berbasis *Person–Event–Location–Time* serta membangun relationship antar entitas dan peristiwa pada Neo4j?
4. Bagaimana melakukan evaluasi terhadap hasil prediksi entitas yang dihasilkan oleh pendekatan *Named Entity Recognition*?
5. Bagaimana melakukan evaluasi terbatas terhadap hasil konstruksi basis data graf?

1.3 Batasan Masalah

Agar penelitian ini tetap terfokus dan dapat diselesaikan sesuai ruang lingkup Tugas Akhir, maka diperlukan sejumlah batasan penelitian. Batasan ini ditetapkan untuk menghindari pembahasan yang terlalu luas serta memastikan bahwa tujuan penelitian dapat dicapai secara terukur. Adapun batasan masalah dalam penelitian ini adalah sebagai berikut:

1. Data yang digunakan berupa korpus teks Sirah Nabawiyah dan diproses menjadi teks.
2. Label node minimal terdiri dari Person, Event, Location, dan Time.
3. Relationship yang dibangun difokuskan pada relasi inti, seperti keterlibatan tokoh pada peristiwa, lokasi terjadinya peristiwa, serta waktu terjadinya peristiwa.
4. Penelitian ini dibatasi sampai tahap konstruksi basis data graf dan evaluasi terbatas, bukan pada pengembangan aplikasi tanya-jawab/*chatbot* secara penuh.

1.4 Tujuan

Penelitian ini bertujuan untuk mengonstruksi basis data graf Sirah Nabawiyah berbasis named-entity relationship menggunakan Neo4j, melalui proses ekstraksi entitas dan relasi dari teks Sirah berbahasa Indonesia, serta melakukan evaluasi terbatas terhadap hasil konstruksi graf. Adapun tujuan spesifik dari penelitian ini adalah sebagai berikut:

1. Menyiapkan data teks Sirah Nabawiyah menjadi dataset yang siap digunakan.
2. Melakukan ekstraksi entitas dari teks Sirah Nabawiyah menggunakan pendekatan *Named Entity Recognition* (NER).
3. Merancang skema basis data graf berbasis *Person–Event–Location–Time* serta membangun relationship antar entitas dan peristiwa menggunakan Neo4j.
4. Melakukan evaluasi terhadap hasil prediksi entitas yang dihasilkan oleh NER untuk menilai kualitas dan konsistensi ekstraksi entitas
5. Melakukan evaluasi terbatas terhadap hasil konstruksi basis data graf untuk menguji kelayakan struktur graf dalam mendukung penelusuran informasi relasional pada Sirah Nabawiyah.

1.5 Manfaat

Penelitian Tugas Akhir ini diharapkan dapat memberikan berbagai manfaat, baik secara teoritis maupun praktis, dalam pengembangan dan pemodelan pengetahuan Sirah Nabawiyah dalam bentuk basis data graf menggunakan Neo4j. Adapun manfaat penelitian ini adalah sebagai berikut:

1.5.1 Manfaat Teoritis

1. Memberikan kontribusi pada kajian ekstraksi informasi dari teks naratif melalui pemodelan berbasis graph.
2. Menjadi referensi penerapan NER dan ekstraksi relasi untuk konstruksi *knowledge graph* pada domain historis/keislaman.

1.5.2 Manfaat Praktis

1. Menghasilkan Graph Database Sirah Nabawiyah yang dapat di-query menggunakan Neo4j untuk penelusuran informasi relasional.
2. Mempermudah penyusunan *use-case* pencarian seperti tokoh-peristiwa, lokasi kejadian, dan timeline peristiwa.

1.5.3 Manfaat Sosial

1. Membantu pengguna (pelajar/peneliti/masyarakat) mengakses informasi Sirah secara lebih terstruktur dan mudah ditelusuri.
2. Mendukung pengembangan aplikasi turunan seperti sistem tanya-jawab berbasis graph atau visualisasi sejarah Sirah.

Halaman ini sengaja dikosongkan.

BAB 2

TINJAUAN PUSTAKA

2.1 Hasil Penelitian Terdahulu

Penyusunan proposal Tugas Akhir tentang konstruksi basis data graf Sirah Nabawiyah ini melibatkan beberapa penelitian terdahulu yang berkaitan dengan *knowledge graph construction*, *information extraction* (khususnya NER dan ekstraksi relasi), serta pemanfaatan *graph database* seperti Neo4j untuk penyimpanan dan penelusuran pengetahuan berbasis relasi. Penelitian-penelitian tersebut digunakan sebagai landasan untuk memahami tahapan umum konstruksi *knowledge graph*, pendekatan yang umum diterapkan pada berbagai domain, serta bentuk evaluasi yang lazim dilakukan untuk menilai kelayakan hasil konstruksi graf. Berikut ringkasan penelitian terdahulu yang menjadi rujukan pada penelitian ini.

Penelitian pertama berjudul “*A Comprehensive Survey on Automatic Knowledge Graph Construction*” yang dilakukan oleh Zhong et al. (2024) menyajikan tinjauan sistematis terkait perkembangan metode konstruksi *knowledge graph* secara otomatis. Studi ini mengkaji lebih dari 300 metode dan melakukan pengelompokan proses konstruksi *knowledge graph* ke dalam tiga tahap utama, yaitu *knowledge acquisition*, *knowledge refinement*, dan *knowledge evolution*. Tahap *knowledge acquisition* meliputi proses perolehan entitas dengan tipe yang lebih spesifik, penyelesaian *coreference*, serta ekstraksi relasi antar-entitas dalam skenario yang kompleks. Sementara itu, tahap *refinement* berfokus pada penyempurnaan graf seperti *knowledge graph completion* dan *knowledge fusion*, dan tahap *evolution* membahas dinamika pengetahuan dalam berbagai kondisi (Zhong et al., 2024).

Penelitian kedua berjudul “*A Knowledge Graph Construction Method for Complex Products Improvement Design*” oleh Ren et al. (2024) membahas konstruksi *knowledge graph* pada domain produk kompleks untuk mendukung perbaikan desain dan pengambilan keputusan berbasis pengetahuan. Penelitian ini menyoroti tantangan data heterogen sepanjang siklus hidup produk dan mengusulkan kerangka representasi pengetahuan terpadu dengan memanfaatkan *knowledge graph*. Metode yang digunakan melibatkan pengumpulan data multi-sumber, ekstraksi pengetahuan, serta representasi pengetahuan desain dan pengetahuan historis melalui model *function-behavior-structure* (FBS). Selanjutnya, *knowledge graph* dikonstruksi di bawah panduan ontologi untuk menjadi basis pengetahuan yang mendukung *knowledge reuse* dan rekomendasi Solusi (Ren et al., 2024).

Penelitian ketiga berjudul “*Automatic knowledge-graph creation from historical documents: The Chilean dictatorship as a case study*” oleh Díaz et al. (2024) berfokus pada konstruksi *knowledge graph* dari dokumen historis terkait periode diktator Chile (1973–1990). Penelitian ini menggunakan Large Language Models (LLM) untuk mengenali entitas dan relasi secara otomatis serta menyelesaikan konflik nilai. Untuk menekan halusinasi, interaksi dengan LLM dibuat grounded menggunakan ontologi sederhana yang membatasi tipe entitas dan relasi. Evaluasi dilakukan dengan membandingkan graf otomatis terhadap gold standard graph yang dibuat dari subset dokumen, dan hasilnya menunjukkan bahwa pendekatan otomatis mampu mengenali sebagian besar entitas dalam gold standard. Studi ini menekankan bahwa perbedaan

hasil tidak selalu berasal dari kegagalan ekstraksi, tetapi dapat dipengaruhi oleh perbedaan granularitas representasi informasi pada graf (Díaz et al., 2024)

Penelitian keempat “*BioKGrapher: Initial evaluation of automated knowledge graph construction from biomedical literature*” oleh Schäfer et al. (2024) berangkat dari masalah ledakan literatur biomedis yang menyulitkan ekstraksi dan penataan pengetahuan secara manual. Penelitian ini memperkenalkan BioKGrapher, yaitu alat konstruksi knowledge graph otomatis dari publikasi skala besar berbasis PubMed IDs, dengan fokus pada konsep biomedis terkait kondisi medis tertentu. Metode yang digunakan diawali dengan Named Entity Recognition and Linking (NER+NEL) untuk mengekstraksi dan menormalisasi konsep biomedis, kemudian memetakan konsep ke UMLS. Konsep yang diekstraksi selanjutnya diberi bobot dan di-re-rank (mis. menggunakan Kullback–Leibler divergence dan penyeimbangan frekuensi lokal), lalu diintegrasikan menjadi knowledge graph hierarkis dengan relasi yang dibentuk menggunakan terminologi seperti SNOMED CT dan NCIt. Hasil penelitian menunjukkan bahwa knowledge graph yang dibangun dapat disejajarkan dengan pedoman klinis (GGPO) dengan F1-score hingga 0,6, serta memberikan peningkatan performa pada tugas hilir multi-label classification (peningkatan micro F1 hingga 0,89 poin persentase dibanding KG non-spesifik dan 2,16 poin dibanding model dasar) (Schäfer et al., 2024).

Penelitian kelima “*Construction of a Traditional Chinese Medicine Dao Yin Science Knowledge Graph Based on Neo4j*” oleh Xie et al. (2023) bertujuan membangun knowledge graph untuk domain Dao Yin pada pengobatan tradisional Tiongkok agar pengguna dapat melakukan pencarian, pembelajaran, dan diseminasi pengetahuan melalui query graf. Metode yang digunakan memanfaatkan BERT–CRF untuk melakukan NER pada literatur terkait Dao Yin, disertai manual *proofreading* guna meningkatkan akurasi, kemudian membangun relasi antar entitas berdasarkan karakteristik domain dan mengimplementasikannya dalam Neo4j. Output yang dihasilkan mencakup knowledge graph dari 3152 dokumen, berisi 2262 node entitas dan 5108 data relasi, dengan 7 kategori atribut entitas dan 7 tipe relasi, serta dapat ditelusuri menggunakan Cypher query (Xie et al., 2023).

Penelitian keenam “*Construction of Military Knowledge Graph Based on Neo4j and MongoDB*” oleh He et al. (2022) membahas kebutuhan menambang informasi yang akurat dari intelijen medan perang yang multi-sumber dan heterogen, di mana tantangan utamanya adalah “kelebihan informasi” serta kesulitan membedakan informasi valid. Penelitian ini mengusulkan konstruksi *panoramic military knowledge graph* dengan menyatukan representasi pengetahuan dari berbagai sumber pada level semantik, sehingga mendukung akumulasi pengetahuan sekaligus asosiasi dan fusi informasi multi-sumber. Output akhirnya disimpan pada Neo4j dan MongoDB untuk menyediakan representasi yang lebih intuitif dan aplikatif, serta terdapat pembahasan terkait skenario penerapan dan arah pengembangan (He et al., 2022).

Penelitian ketujuh “*Enhanced Entity Recognition of Islamic Hadiths based-on Hybrid LSTM and AraBERT Model*” oleh Nados (2024) berfokus pada pelatihan, evaluasi, dan pengembangan model *Named-Entity Recognition* (NER) untuk teks hadis Islam berbahasa Arab. Penelitian ini menggunakan dataset Hadith Noor dan menerapkan skema penandaan BIO (*Begin–Inside–Outside*) pada proses sequence labeling setelah teks di-tokenize. Dataset mengandung delapan tipe entitas (seperti nama perawi dan lokasi). Penelitian membandingkan tiga model, yaitu AraBERT, LSTM, dan model hibrida AraBERT–LSTM, di mana model hibrida mencapai performa tertinggi dengan akurasi sekitar 0,981 (Nados, 2024).

Penelitian kedelapan “*Graph-based Named Entity Information Retrieval from News Articles using Neo4j*” oleh Chaudhary et al. (2024) bertujuan membangun sistem cerdas yang mengonversi teks mentah menjadi *knowledge graph* untuk mendukung penelusuran informasi berbasis graf. Penelitian ini menekankan bahwa penggunaan alat *entity linking* dan *relation extraction* yang tersedia secara terpisah (seperti Spacy, NLTK, Flair) dapat menjadi kurang efisien jika tidak diintegrasikan dengan baik, sehingga penelitian mengusulkan pendekatan integrasi yang lebih efisien untuk membentuk graf. Output utama penelitian adalah *knowledge graph* yang disimpan pada *graph database* Neo4j dan dapat dimanfaatkan untuk kebutuhan analisis data serta pengambilan keputusan (Chaudhary et al., 2024).

Lalu terdapat karya berjudul “*Knowledge Extraction from Multilingual and Historical Texts for Advanced Question Answering*” oleh Graciotti (2023) membahas tantangan membangun *knowledge graph* dari teks, khususnya ketika berhadapan dengan dokumen multibahasa dan historis. Penelitian ini mengusulkan metode yang menggabungkan pendekatan *Semantic Web* dan *Natural Language Processing* untuk mendukung aplikasi *question answering* pada repositori teks diakronik (lintas waktu). Studi ini menyoroti kesulitan khas teks historis, seperti degradasi data akibat OCR serta tantangan *Entity Linking* yang bias terhadap entitas modern. *Framework* dievaluasi menggunakan korpus dokumen historis pada domain Musical Heritage (Graciotti, 2023).

Penelitian terakhir berjudul “*The Construction of Knowledge Graph of Newspaper Distribution in Yan’an Period and Frontend Visualization*” oleh Yifan (2023) mengangkat masalah data distribusi surat kabar periode Yan’an yang tersebar, keterhubungan data lemah, serta penyajian teks linear yang menghambat pemanfaatan literatur. Untuk mengatasi hal tersebut, penelitian ini mengusulkan metode konstruksi *knowledge graph* yang mencakup teknologi kunci seperti *information extraction*, *knowledge fusion*, *knowledge processing*, serta *knowledge graph storage and construction*. Selain membangun *knowledge graph*, penelitian ini juga merealisasikan sistem visualisasi *front-end* untuk mendukung query, analisis, dan penyajian hasil. Outputnya berupa *knowledge graph* dengan 15 ontologies, 27.349 relationship, 4.074 newspapers, dan 10.616 entities (Du, 2023). Ringkasan perbandingan penelitian terdahulu dapat dilihat pada Tabel 2.1

Tabel 2.1 Ringkasan Penelitian Terdahulu

Penelitian	Sumber Data	Metode	Analisis
<i>A Comprehensive Survey on Automatic Knowledge Graph Construction</i> (Zhong et al., 2024)	Survey >300 metode KGC	Review sistematis; memetakan KGC ke tahap akuisisi–refinement–evolution	Penelitian ini menunjukkan bahwa konstruksi <i>knowledge graph</i> dapat dipahami sebagai proses bertahap, mulai dari akuisisi pengetahuan (ekstraksi entitas/relasi, coreference) hingga penyempurnaan dan evolusi graf. Kerangka ini membantu merumuskan pipeline konstruksi graf pada penelitian Sirah agar tahapannya jelas dan terukur.

<i>A Knowledge Graph Construction Method for Complex Products Improvement Design</i> (Ren et al., 2024)	Data heterogen siklus hidup produk	Ekstraksi pengetahuan multi-sumber; pemodelan FBS; ontologi	Penelitian ini menunjukkan bahwa pemodelan berbasis ontologi dan kerangka FBS dapat menyatukan pengetahuan dari data heterogen ke dalam representasi graf yang konsisten. Hal ini menegaskan pentingnya perancangan skema/ontologi sebelum membangun graf, meskipun domainnya berbeda dari Sirah.
<i>Automatic knowledge-graph creation from historical documents: The Chilean dictatorship as a case study</i> (Díaz et al., 2024)	Dokumen historis dan subset <i>gold standard</i>	LLM untuk ekstraksi entitas & relasi; grounding ontologi sederhana; evaluasi vs gold standard	Penelitian ini menunjukkan bahwa konstruksi knowledge graph otomatis pada dokumen historis mampu mengenali sebagian besar entitas pada gold standard ketika proses ekstraksi dibatasi oleh ontologi untuk mengurangi halusinasi. Perbedaan hasil terutama dipengaruhi granularitas representasi (detail event/lokasi), sehingga relevan untuk TA Sirah yang juga berpotensi menghadapi isu granularitas.
<i>BioKGrapher: Initial evaluation of automated knowledge graph construction from biomedical literature</i> (Schäfer et al., 2024)	Literatur biomedis (PubMed IDs)	NER+NEL; normalisasi UMLS; pembobotan konsep; pembentukan KG hierarkis	Penelitian ini menunjukkan bahwa konstruksi KG otomatis dapat disejajarkan dengan pedoman klinis dengan F1-score hingga 0,6 dan memberikan peningkatan performa pada tugas hilir (<i>multi-label classification</i>). Ini menjadi contoh evaluasi berbasis metrik yang bisa menginspirasi evaluasi terbatas pada graf Sirah.
<i>Construction of a Traditional Chinese Medicine Dao Yin Science Knowledge Graph Based on Neo4j</i> (Xie et al., 2023)	3152 dokumen Dao Yin	BERT-CRF dan proofreading manual; pembentukan relasi; implementasi Neo4j dan Cypher	Penelitian ini menunjukkan bahwa NER berbasis BERT-CRF yang dilengkapi <i>proofreading</i> manual dapat menghasilkan <i>knowledge graph</i> skala besar (ribuan dokumen) dengan ribuan node dan relasi, serta

			dapat ditelusuri lewat Cypher. Ini relevan karena menunjukkan pipeline praktis NER → relasi → Neo4j yang mirip dengan target konstruksi graf Sirah.
<i>Construction of Military Knowledge Graph Based on Neo4j and MongoDB (He et al., 2022)</i>	Informasi intelijen militer multi-sumber heterogen	Penyatuan representasi pengetahuan; fusi semantik; penyimpanan Neo4j dan MongoDB	Penelitian ini menunjukkan bahwa knowledge graph dapat digunakan untuk menyatukan dan mengasosiasikan informasi heterogen pada level semantik, sehingga mengurangi masalah “kelebihan informasi” dan meningkatkan keterhubungan pengetahuan. Studi ini relevan sebagai referensi konsep fusi/penyelarasan pengetahuan, meskipun domainnya bukan Sirah.
<i>Enhanced Entity Recognition of Islamic Hadiths based-on Hybrid LSTM and AraBERT Model (Nados, 2024)</i>	Hadith Noor dataset (Arab), 8 tipe entitas	BIO tagging; komparasi AraBERT vs LSTM vs AraBERT–LSTM	Penelitian ini menunjukkan bahwa model hibrida AraBERT–LSTM mencapai performa tinggi untuk NER hadis berbahasa Arab dengan akurasi sekitar 0,981, melampaui model tunggal. Ini memperkuat argumen bahwa NER efektif diterapkan pada teks Islam, namun perlu adaptasi bahasa dan label untuk konteks Sirah berbahasa Indonesia.
<i>Graph-based Named Entity Information Retrieval from News Articles using Neo4j (Chaudhary et al., 2024)</i>	Artikel berita	Integrasi <i>entity linkage</i> dan <i>relation extraction</i> ; konstruksi KG; Neo4j	Penelitian ini menunjukkan bahwa mengintegrasikan entity linkage dan ekstraksi relasi dapat mengonversi teks mentah menjadi knowledge graph secara lebih efisien dibanding penggunaan alat yang terpisah-pisah. Ini relevan karena mendukung ide pipeline terpadu untuk membangun graf Sirah di Neo4j.
<i>Knowledge Extraction from Multilingual and</i>	Korpus dokumen	Kombinasi <i>Semantic Web</i>	Penelitian ini menunjukkan bahwa konstruksi

<i>Historical Texts for Advanced Question Answering (Graciotti, 2023)</i>	historis (<i>Musical Heritage</i>)	dan NLP; menangani noise OCR dan bias entity linking	pengetahuan dari teks historis menghadapi tantangan khas seperti degradasi OCR dan entity linking yang bias terhadap entitas modern, sehingga memerlukan strategi khusus untuk menjaga kualitas ekstraksi. Temuan ini relevan karena teks Sirah berpotensi memiliki noise OCR dan variasi penulisan entitas.
<i>The Construction of Knowledge Graph of Newspaper Distribution in Yan'an Period and Frontend Visualization (Yifan, 2023)</i>	Data surat kabar/periode Yan'an	IE + knowledge fusion + processing + storage; visualisasi front-end	Penelitian ini menunjukkan bahwa knowledge graph dapat meningkatkan keterhubungan data historis yang sebelumnya tersebar, ditandai dengan graf berskala besar (15 ontologi, puluhan ribu relasi, ribuan entitas) dan dukungan visualisasi untuk query/analisis. Ini relevan sebagai bukti bahwa KG efektif untuk korpus historis, meski TA Sirah tidak wajib membangun front-end.

Berdasarkan penelitian terdahulu, terlihat bahwa konstruksi knowledge graph umumnya memerlukan tahapan ekstraksi entitas dan relasi, pemodelan skema, serta penyimpanan graf (seringnya Neo4j) agar pengetahuan dapat ditelusuri melalui query graf. Namun, sebagian besar studi masih berfokus pada domain berita, biomedis, militer, atau arsip sejarah tertentu, dan belum secara spesifik membahas konstruksi graf untuk Sirah Nabawiyah berbahasa Indonesia dengan label minimal *Person–Event–Location–Time*. Oleh karena itu, penelitian ini mengadaptasi pipeline konstruksi knowledge graph untuk domain Sirah, dengan fokus pada konstruksi basis data graf Neo4j dan evaluasi terbatas untuk memastikan kualitas ekstraksi entitas–relasi serta kelayakan graf untuk penelusuran relasional.

2.2 Dasar Teori

Dasar teori terdiri atas Sirah Nabawiyah, *Optical Character Recognition (OCR)*, *Named-Entity Recognition (SRL-based dan LLM-based)*, *Knowledge Graph*, Neo4j, Ekstraksi Relasi, dan Evaluasi (*Similarity*) yang dijelaskan sebagai berikut.

2.2.1 Sirah Nabawiyah

Sirah Nabawiyah merupakan narasi historis yang merekam perjalanan hidup Nabi Muhammad SAW beserta konteks sosial dan peristiwa yang menyertainya (Solihin, 2022). Dalam tradisi keilmuan Islam, Sirah memiliki keterkaitan erat dengan hadis; hadis dapat

dipandang sebagai salah satu sumber penting dalam penulisan Sirah, sementara Sirah juga membantu memahami hadis melalui konteks peristiwa dan kronologi. Pembahasan tentang perbedaan dan keterkaitan keduanya—termasuk posisi hadis sebagai bagian dari Sirah namun tidak seluruh Sirah berada dalam ruang lingkup hadis—sering dibahas dalam kajian ilmiah kontemporer (Kharis, 2024).

Dalam historiografi Islam, Sirah berkembang sejak periode awal sebagai rujukan penting setelah kajian hadis/sunnah. Karya klasik seperti Sirah Ibn Ishaq yang disempurnakan Ibn Hisham menunjukkan upaya sistematis menuturkan kehidupan Nabi secara runtut dan menyatukan berbagai Riwayat (Prayogi et al., 2022). Kajian modern menempatkan karya-karya tersebut sebagai fondasi penting, sekaligus mengkajinya dalam kerangka historiografi kontemporer melalui analisis metode penulisan, karakter narasi, dan studi komparatif antar karya Sirah modern. Dengan demikian, Sirah dipahami bukan hanya sebagai teks religius, tetapi juga karya sejarah dengan pendekatan penulisan yang beragam (Abror & Rahma, 2024).

Dari sisi bentuk teks, Sirah umumnya disajikan sebagai narasi kronologis dengan unit faktual seperti tokoh, peristiwa, lokasi, dan waktu yang hubungan antarunitnya sering tersirat dalam struktur kalimat dan paragraf. Karakter naratif ini membuat informasi relasional tersebar pada banyak bagian teks. Berdasarkan karakteristik tersebut, Sirah Nabawiyah dapat dipandang sebagai korpus naratif kaya entitas dan peristiwa yang menjadi dasar penelitian ini—mulai dari pembentukan korpus, pembersihan OCR, hingga ekstraksi entitas dan relasi—agar unit informasi dapat direpresentasikan lebih terstruktur dalam basis data graf.

2.2.2 *Optical Character Recognition*

Optical Character Recognition (OCR) adalah proses mengubah dokumen berbasis citra—seperti hasil scan atau foto PDF—menjadi teks digital yang dapat diolah lebih lanjut oleh sistem komputer (Kushavaha, 2024). Dalam penelitian ini, OCR berperan sebagai tahap awal untuk membentuk korpus teks Sirah Nabawiyah, sehingga seluruh pipeline ekstraksi entitas dan relasi sangat bergantung pada kualitas keluaran OCR.

Pada praktiknya, teks hasil OCR sering mengandung *noise* seperti salah karakter, spasi tidak konsisten, pemenggalan kata, baris yang tergabung/terpisah tidak semestinya, serta artefak *header–footer*. Kesalahan semacam ini tidak hanya mengurangi keterbacaan, tetapi juga dapat menurunkan performa tugas NLP di tahap berikutnya, terutama tugas yang sensitif pada bentuk token dan batas entitas seperti NER/NEL, serta pencarian berbasis *retrieval* (Francis & Sangeetha, 2025). Kualitas OCR juga dapat berdampak nyata pada performa sistem retrieval dan QA/RAG, dan NER termasuk salah satu tugas yang paling rentan terhadap error OCR ketika tingkat kesalahan meningkat (Song, 2026).

Dengan adanya permasalahan tersebut, OCR umumnya diikuti oleh langkah pasca-pemrosesan (*post-OCR correction*) atau strategi perbaikan keluaran, baik berbasis aturan maupun pembelajaran mesin, untuk memperbaiki error tertentu pada output OCR. Pendekatan pasca-pemrosesan ini penting ketika dokumen memiliki format teknis atau struktur teks yang tidak selalu “mengalir” secara semantik, sehingga error OCR tidak selalu dapat dikoreksi hanya dengan koreksi berbasis kamus (Viana da Silva et al., 2023).


2.2.3 Named-Entity Recognition

Named-Entity Recognition (NER) adalah tugas dalam NLP untuk mengenali span teks yang menyebut entitas bernama dan mengklasifikasikannya ke dalam kategori semantik yang telah ditentukan, seperti person, location, dan organization (Li et al., 2022). Dalam penerapannya, NER tidak hanya membantu dalam memahami isi teks secara semantik, tetapi juga menjadi fondasi bagi berbagai tugas lanjutan seperti information extraction dan relation extraction, sistem tanya jawab, serta konstruksi struktur pengetahuan seperti knowledge base dan knowledge graph (Xu et al., 2024; Zhao et al., 2024). Kemampuan NER dalam mengidentifikasi dan mengkategorikan entitas ini membuat proses pengolahan data teks menjadi lebih terstruktur dan menghasilkan output yang lebih baik. Jenis label entitas yang biasa digunakan dalam NER dapat dilihat pada tabel 2.2 yang terdapat banyak tipe. Seluruh label tersebut dapat disesuaikan dengan kebutuhan atau konteks analisis pada domain tertentu.

Tabel 2.2 Contoh Daftar Label NER

Label	Deskripsi
<i>PERSON</i>	Nama orang atau tokoh, bisa berupa nama asli atau nama panggilan
<i>LOC</i>	Nama lokasi geografis, seperti nama tempat, kota, gunung, dll
<i>ORG</i>	Nama organisasi atau institusi
<i>DATE</i>	Informasi waktu bisa berupa tanggal atau periode
<i>TIME</i>	Sama seperti “DATE” tetapi dengan durasi kurang dari 1 hari atau waktu spesifik tertentu
<i>EVENT</i>	Nama sebuah kejadian, seperti perang,

Sebagai gambaran, gambar 2.1 menunjukkan penerapan NER pada potongan paragraph sebuah teks berbahasa Inggris. Setiap entitas yang ditemukan diberikan label dengan warna berbeda-beda, seperti *PERSON* untuk “Tencent”, lalu *ORG* untuk “Google”, “IBM”, dan “Microsoft”, serta *DATE* untuk “2018-2024” dan “2017”. Gambaran ini menunjukkan NER menandai dan mengelompokkan elemen penting dalam teks, sehingga informasi yang diterima lebih terstruktur.



Gambar 2.1 Contoh Hasil Penerapan NER pada Teks Bahasa Inggris (Vyas, 2018)

Secara umum, NER banyak diformulasikan sebagai sequence labeling menggunakan skema seperti BIO/IOB untuk menandai awal dan kelanjutan entitas pada level token. Pendekatan modern berbasis representasi kontekstual (Transformer) cenderung unggul karena mampu membedakan entitas berdasarkan konteks kalimat, terutama pada teks naratif yang memiliki ambiguitas rujukan dan variasi bentuk penyebutan. Sejalan dengan perkembangan terkini, muncul pendekatan LLM-based NER, yaitu mengekstraksi entitas melalui prompting dan format keluaran terstruktur. Salah satu tantangan pendekatan LLM adalah kecenderungan menandai entitas secara berlebihan (*hallucination/over-labeling*), sehingga beberapa penelitian mengusulkan strategi self-verification atau langkah verifikasi setelah ekstraksi untuk meningkatkan reliabilitas hasil NER dari LLM.

2.2.3.1 Semantic Role Labeling NER

Semantic Role Labeling (SRL) merupakan teknik semantic parsing tingkat dangkal yang merepresentasikan makna kalimat dalam bentuk struktur predikat–argumen, sehingga informasi inti seperti ‘siapa melakukan apa, kepada siapa, kapan, dan di mana’ dapat diidentifikasi secara eksplisit (Jindal et al., 2022). Dalam SRL, predikat diperlakukan sebagai pusat kejadian, sedangkan argumen dan keterangan (seperti peran pelaku, objek/tema, lokasi, dan waktu) dilabeli sesuai perannya terhadap predikat. Pendekatan ini relevan untuk ekstraksi informasi dari teks naratif karena membantu mengekstrak kerangka peristiwa beserta partisipan dan konteksnya secara lebih terstruktur (Santana et al., 2023).


Pada penelitian ini, SRL dimanfaatkan sebagai dasar pembentukan graf berbasis peristiwa pada skenario NER+SRL. Struktur predikat–argumen diproyeksikan ke dalam node dan edge pada graf. Dalam skema ini, setiap predikat utama pada kalimat diperlakukan sebagai kandidat node *Event* (misalnya disimpan dengan atribut berupa *trigger* dan *evidence* kalimat), sedangkan span argumen SRL dipetakan menjadi kandidat entitas. Selanjutnya, NER digunakan untuk menetapkan tipe entitas (*Person*, *Location*, dan *Time*) pada argumen SRL, sehingga node yang dibentuk konsisten dengan skema label yang dirancang. Setelah node terbentuk, relationship dibangun melalui pemetaan peran SRL: argumen pelaku dihubungkan sebagai relasi keterlibatan tokoh terhadap event, sedangkan keterangan lokasi dan waktu

dihubungkan dari event menuju node bertipe *Location* dan *Time*. Strategi pemanfaatan SRL untuk mengekstrak struktur graf dari teks ini sejalan dengan penelitian yang menunjukkan bahwa keluaran SRL dapat diformalisasi menjadi representasi graf pengetahuan berbasis peran dan peristiwa (Alam et al., 2021).

2.2.3.2 LLM-Based NER

LLM-Based Named-Entity Recognition (LLM-based NER) adalah pendekatan ekstraksi entitas yang memanfaatkan *Large Language Model* untuk mengidentifikasi dan mengelompokkan entitas langsung dari teks melalui instruksi (*prompting*), alih-alih murni sebagai *sequence labeling* seperti NER klasik. Salah satu motivasi utama pendekatan ini adalah adanya “kesenjangan” antara NER yang secara alami berupa pelabelan token dan LLM yang beroperasi sebagai model generatif; penelitian GPT-NER menunjukkan bahwa formulasi ulang NER menjadi tugas generatif (misalnya menandai span entitas pada teks keluaran) dapat membuat LLM lebih cocok untuk tugas NER, sekaligus menambahkan mekanisme verifikasi diri untuk menekan kecenderungan *over-labeling* (menandai entitas yang tidak ada).

Dalam penelitian ini, LLM-based NER diposisikan sebagai skenario pembandingan untuk menghasilkan node graf dengan label minimal *Person*, *Event*, *Location*, dan *Time*. Secara operasional, teks (per kalimat atau per paragraf) diberikan ke LLM dengan prompt yang mendefinisikan skema label, kriteria penandaan, serta format keluaran terstruktur. Praktik pengeluaran hasil ekstraksi dalam skema yang konsisten (termasuk format JSON) banyak digunakan pada riset ekstraksi informasi terstruktur berbasis LLM karena memudahkan tahap *post-processing*, validasi, dan integrasi ke basis data (Dagdelen et al., 2024). Selain itu, performa LLM pada NER dapat ditingkatkan melalui perancangan prompt yang sistematis (*prompt engineering*), terutama pada domain khusus, sehingga pendekatan ini relevan ketika data anotasi terbatas (Claudio M, 2025).




Gambar 2.2 Alur Pengerjaan PromptNER

2.2.4 Knowledge Graph

Knowledge graph (KG) adalah representasi pengetahuan berbasis graf yang memodelkan entitas (misalnya orang, tempat, waktu, dan peristiwa) beserta relasi di antaranya sehingga informasi tidak hanya tersimpan sebagai teks naratif, tetapi menjadi struktur yang dapat ditelusuri secara relasional (Ji et al., 2021). Dalam banyak literatur modern, KG dipahami sebagai graf yang merekam fakta atau keterkaitan antar-entitas, umumnya dalam bentuk triple head–relation–tail atau struktur yang setara, sehingga mendukung penelusuran hubungan dan integrasi pengetahuan lintas sumber (Chen et al., 2023). Salah satu karakter penting dari knowledge graph adalah adanya representasi eksplisit terhadap relasi. Alih-alih pengguna harus membaca narasi untuk menyimpulkan hubungan, KG menyimpan hubungan tersebut sebagai

edge, sehingga kueri berbasis relasi (seperti “siapa terkait dengan peristiwa X” atau “peristiwa apa terjadi di lokasi Y pada waktu Z”) dapat dilakukan melalui pencocokan pola graf.




Gambar 2.3 Contoh Penerapan Entitas dan Relasi dalam Knowledge Graph (Ji et al., 2021)

Dalam konteks konstruksi otomatis, KG biasanya dilengkapi skema/ontologi (eksplisit atau implisit) untuk mengatur tipe node dan tipe relasi agar konsisten, sekaligus membantu proses normalisasi dan penggabungan pengetahuan. Dari sisi proses pembentukan, survei konstruksi knowledge graph menjelaskan bahwa KG umumnya dibangun melalui tahapan akuisisi pengetahuan (seperti ekstraksi entitas dan relasi dari teks), penyempurnaan (seperti penyesuaian entitas, deduplikasi, atau perbaikan kualitas), serta evolusi (pemutakhiran ketika data baru ditambahkan atau skema berubah) (Ji et al., 2021). Selain itu, karena KG sering tidak lengkap, penelitian tentang knowledge graph completion berkembang untuk melengkapi fakta yang hilang atau memperbaiki keterhubungan graf (Cai et al., 2022).

2.2.5 Neo4j

Neo4j adalah graph database yang menyimpan data dalam bentuk property graph, yaitu graf yang terdiri dari node dan relationship (edge), di mana keduanya dapat memiliki properties (atribut). Node dapat diberi satu atau lebih label untuk mengelompokkan tipe entitas (misalnya Person, Event, Location, Time), sedangkan relationship memiliki type untuk menyatakan jenis keterkaitan (misalnya keterlibatan tokoh pada peristiwa atau lokasi terjadinya peristiwa) (Neo4j, n.d.-a). Model seperti ini relevan untuk representasi knowledge graph karena struktur pengetahuan dapat dimodelkan secara eksplisit sebagai node-edge dan dapat ditelusuri berdasarkan pola hubungan, bukan sekadar pencarian kata pada dokumen.



Gambar 2.4 Contoh Implementasi Neo4j (Chaudhary et al., 2024)

Neo4j menyediakan bahasa query Cypher yang mendukung pattern matching untuk menelusuri relasi pada graf. Dengan Cypher, pengguna dapat mengekspresikan kebutuhan penelusuran relasional secara natural, misalnya mencari pola keterkaitan “(Person)–(Event)–(Location)” atau membangun lintasan berdasarkan relasi tertentu (Neo4j, n.d.-b). Dalam konteks penelitian ini, Cypher penting karena menjadi mekanisme utama untuk melakukan uji kelayakan graf melalui query representatif (misalnya menelusuri tokoh yang terlibat pada event tertentu, menampilkan event pada lokasi tertentu, atau membentuk timeline berdasarkan Time).

Dari sisi keandalan data, Neo4j mendukung transaksi dengan properti ACID (*atomicity, consistency, isolation, durability*) sehingga perubahan terhadap graf dapat dijaga konsistensinya, terutama saat proses konstruksi dilakukan bertahap (*insert node, insert relationship, deduplikasi, dan pembaruan properti*) (Neo4j, n.d.-c). Selain itu, Neo4j menyediakan constraints dan indexes untuk menjaga integritas dan meningkatkan performa query; misalnya *uniqueness constraint* untuk memastikan suatu node ID tidak duplikat, yang secara internal didukung oleh index (Neo4j, n.d.-d). Praktik ini relevan untuk penelitian karena membantu mencegah duplikasi entitas saat proses normalisasi/penyatuan nama dan mempercepat query evaluasi pada properti yang sering dipakai.

2.2.6 Ekstraksi Relasi

Ekstraksi relasi (*relation extraction*) adalah proses mengidentifikasi dan mengklasifikasikan hubungan semantik antara dua unit informasi di dalam teks—umumnya antar entitas, atau antara entitas dengan peristiwa—sehingga informasi dapat direpresentasikan sebagai fakta terstruktur. Dalam kerangka *information extraction*, ekstraksi relasi biasanya dilakukan setelah entitas dikenali (NER), karena relasi dibangun berdasarkan pasangan entitas yang terdeteksi dan konteks kalimat/dokumen yang menyertainya (Yang et al., 2022). Salah satu literatur survei menunjukkan bahwa pendekatan modern ekstraksi relasi banyak memanfaatkan *language model* (berbasis BERT/Transformer) dan digunakan luas dalam berbagai domain karena menjadi komponen kunci pembentukan struktur pengetahuan seperti knowledge graph (Diaz-Garcia & Lopez, 2025).

Secara umum, metode ekstraksi relasi dapat dikelompokkan menjadi beberapa pendekatan. Pertama, pendekatan *supervised/neural relation extraction* yang memprediksi tipe relasi dari

pasangan entitas berdasarkan representasi konteks kalimat atau dokumen; variasinya mencakup *sentence-level* maupun *document-level relation extraction* ketika informasi relasi tersebar lintas kalimat. Kedua, pendekatan *pattern-based/rule-based* yang membangun relasi dari pola linguistik tertentu (mis. kata kerja pemicu, pola dependensi). Ketiga, pendekatan *Open Information Extraction (OpenIE)* yang mengekstrak relasi secara terbuka tanpa daftar relasi yang kaku dan sering dipakai sebagai langkah awal untuk konstruksi basis pengetahuan dari korpus besar. Perkembangan riset OpenIE berbasis neural menunjukkan pergeseran ke model yang lebih fleksibel dalam menemukan fakta relasional dari teks (Zhou et al., 2022). Namun, pada teks naratif panjang, relasi sering bersifat implisit, berjarak lintas kalimat, dan dipengaruhi rujukan (*coreference*), sehingga ekstraksi relasi menjadi lebih menantang dibanding teks pendek. Salah satu studi terkait *document-level relation extraction* menekankan bahwa relasi “di dunia nyata” tidak selalu muncul eksplisit dalam satu kalimat dan membutuhkan penalaran konteks dokumen (Li et al., 2023).

2.2.7 Evaluasi

Evaluasi dilakukan untuk mengukur kualitas hasil ekstraksi informasi serta validitas struktur basis data graf yang dibangun berdasarkan teks Sirah Nabawiyah. Evaluasi ini sejalan dengan peran penting ekstraksi relasi sebagai dasar pembentukan knowledge graph yang lengkap dan mendukung aplikasi tanya-jawab (Zhao et al., 2024). Karena penelitian ini berfokus pada tahap konstruksi basis data graf dan belum mengembangkan aplikasi tanya-jawab secara menyeluruh, evaluasi yang dilakukan bersifat terbatas, yakni berupa penilaian kualitas tripel hasil ekstraksi serta konsistensi struktur graf. Pendekatan tersebut sesuai dengan praktik umum pada penelitian knowledge graph tahap awal, di mana metode konstruksi dievaluasi secara terpisah dari aplikasi turunannya agar efektivitas pendekatan yang diusulkan dapat dipahami secara lebih jelas Paulheim (2017)(Paulheim, 2017).

Secara umum, evaluasi dalam penelitian ini mencakup dua aspek utama, yakni evaluasi hasil *Named Entity Recognition (NER)* serta evaluasi struktur basis data graf yang dibangun menggunakan Neo4j.

2.2.7.1 Evaluasi Hasil *Named Entity Recognition (NER)*

Evaluasi *Named Entity Recognition (NER)* bertujuan untuk mengukur kemampuan metode dalam mengekstraksi serta mengklasifikasikan entitas dari teks Sirah Nabawiyah. Evaluasi ini dilakukan dengan membandingkan hasil prediksi entitas terhadap data acuan (ground truth) yang telah dilabeli secara manual pada sebagian data uji. Pendekatan tersebut umum diterapkan pada skenario anotasi parsial di mana tidak semua entitas berhasil diidentifikasi (Ding et al., 2025; Effland & Collins, 2021). Penggunaan evaluasi parsial ini memang lazim pada domain khusus serta teks historis atau naratif yang panjang, mengingat anotasi penuh terhadap seluruh korpus memerlukan biaya dan waktu yang sangat besar (Ehrmann et al., 2024; Liu et al., 2025).

Dalam konteks evaluasi tersebut, pemilihan metrik yang tepat merupakan aspek yang sangat penting. Metrik yang kurang sesuai dapat menghasilkan gambaran yang menyesatkan tentang kemampuan model, terutama pada data dengan distribusi kelas yang tidak seimbang. Pada tugas *Named Entity Recognition (NER)*, perbedaan frekuensi kemunculan antar kelas entitas—seperti *Person*, *Event*, *Location*, dan *Time*—mengharuskan penggunaan metrik yang mampu memberikan penilaian performa secara lebih representatif. Oleh karena itu, evaluasi tidak hanya mengandalkan satu metrik tunggal, melainkan menggabungkan *precision*, *recall*, dan *F1-score* guna mengukur ketepatan serta kelengkapan hasil ekstraksi entitas. Selain itu,

confusion matrix digunakan sebagai alat bantu visual untuk menggambarkan distribusi prediksi dan mengidentifikasi jenis kesalahan, seperti *false positive* dan *false negative*.

1. Presisi (Precision)

Presisi merupakan metrik evaluasi yang mengukur tingkat ketepatan model dalam menghasilkan prediksi positif yang benar. Dalam konteks ekstraksi informasi dan Named Entity Recognition (NER), presisi mencerminkan proporsi entitas yang diprediksi oleh model yang memang benar-benar sesuai dengan entitas yang seharusnya dikenali (Lian et al., 2024). Dengan kata lain, presisi menjawab pertanyaan: *dari semua entitas yang diprediksi sebagai suatu kelas tertentu, berapa banyak yang benar?*

Secara matematis, presisi dihitung sebagai perbandingan antara jumlah prediksi benar pada kelas positif (*true positive*, TP) dengan total prediksi positif yang dihasilkan model, yang terdiri dari *true positive* (TP) dan *false positive* (FP). Rumus presisi ditunjukkan pada Persamaan (2.1)

$$\text{Presisi} = \frac{TP}{TP + FP} \quad (2.1)$$

Nilai presisi berada pada rentang 0 hingga 1 (atau 0% hingga 100%). Semakin tinggi nilainya, semakin rendah proporsi kesalahan dalam prediksi positif yang dihasilkan model. Metrik ini menjadi sangat penting pada kasus di mana prediksi positif yang keliru perlu diminimalkan, misalnya ketika kesalahan pengenalan entitas dapat menyebabkan pembentukan relasi yang salah pada basis data graf (Lian et al., 2024). Namun demikian, presisi tidak memperhitungkan kesalahan akibat kegagalan model dalam mengenali entitas yang seharusnya terdeteksi (*false negative*). Oleh karena itu, meskipun nilai presisi tinggi, model belum tentu mampu menangkap seluruh entitas yang relevan. Untuk memperoleh gambaran performa yang lebih komprehensif, presisi perlu dikombinasikan dengan metrik recall.

2. Recall

Recall merupakan metrik evaluasi yang mengukur kemampuan model dalam mengenali seluruh data yang memang termasuk ke dalam kelas positif. Dalam tugas *Named Entity Recognition* (NER), recall menunjukkan proporsi entitas yang seharusnya dikenali yang berhasil diekstraksi oleh model (Zeynali Tazehkandi & Nowkarizi, 2020). Dengan kata lain, recall menjawab pertanyaan: *dari semua entitas yang seharusnya terdeteksi, berapa banyak yang berhasil dikenali dengan benar?*

Secara matematis, *recall* dirumuskan sebagai berikut pada Persamaan 2.3

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2.2)$$

Nilai recall juga berkisar antara 0 hingga 1 (atau 0% hingga 100%). Semakin tinggi nilainya, semakin baik kemampuan model dalam mengidentifikasi seluruh entitas yang memang relevan. Metrik ini menjadi sangat krusial pada situasi di mana terlewatnya satu entitas saja dapat memengaruhi hasil analisis lebih lanjut secara signifikan, misalnya dalam pembentukan node dan hubungan pada basis data graf (Zeynali Tazehkandi & Nowkarizi, 2020). Meskipun recall menekankan pada kelengkapan ekstraksi entitas, metrik ini tidak mempertimbangkan seberapa

tepat prediksi positif yang dihasilkan. Model yang memiliki nilai recall tinggi bisa saja menghasilkan banyak prediksi positif, tetapi di antaranya terdapat pula kesalahan. Karenanya, mengandalkan recall secara sendiri-sendiri cenderung memberikan penilaian yang kurang seimbang sehingga perlu dipadukan dengan presisi.

3. F1-Score

F1-score merupakan metrik evaluasi yang dirancang untuk memberikan ukuran kinerja tunggal dengan mempertimbangkan keseimbangan antara presisi dan *recall*. Metrik ini sangat berguna pada tugas ekstraksi informasi, termasuk *Named Entity Recognition* (NER), karena keberhasilan sistem tidak hanya ditentukan oleh ketepatan prediksi entitas (presisi), tetapi juga oleh kemampuannya dalam menemukan seluruh entitas yang relevan (recall). F1-score menggabungkan kedua aspek tersebut menggunakan rata-rata harmonik, sehingga nilai yang dihasilkan akan sensitif terhadap ketidakseimbangan antara presisi dan recall (Powers, 2020).

Secara matematis, F1-score dirumuskan sebagai berikut pada Persamaan 2.3

$$F1\text{-score} = 2 \times \frac{(\text{Presisi} \times \text{Recall})}{(\text{Presisi} + \text{Recall})} \quad (2.3)$$

Penggunaan rata-rata harmonik pada F1-score menyebabkan metrik ini memberikan penalti yang lebih besar apabila salah satu komponen bernilai rendah. Dengan demikian, F1-score mendorong model untuk mencapai keseimbangan antara presisi dan recall, bukan hanya mengoptimalkan salah satunya. Karakteristik ini menjadikan F1-score lebih representatif dibandingkan akurasi pada kasus data tidak seimbang, yang umum dijumpai pada NER, terutama ketika jumlah entitas tertentu jauh lebih sedikit dibandingkan kelas non-entitas (Powers, 2020).

2.2.7.2 Evaluasi Basis Data Graf Berbasis Neo4j

Evaluasi basis data graf pada penelitian ini bertujuan untuk menilai kualitas dan kelayakan graf yang dibangun dari hasil ekstraksi entitas dan relasi teks Sirah Nabawiyah. Mengingat penelitian ini berfokus pada tahap konstruksi basis data graf dan belum mencakup pengembangan sistem aplikasi tanya-jawab secara penuh, evaluasi dilakukan secara terbatas dengan menekankan evaluasi fungsional berbasis skenario kueri. Pendekatan ini umum digunakan pada penelitian knowledge graph tahap awal untuk memverifikasi apakah struktur graf telah mampu merepresentasikan pengetahuan domain dan mendukung penelusuran informasi berbasis relasi (Anuyah et al., 2024; Choi & Jung, 2025).

Evaluasi berbasis skenario kueri dilakukan dengan merancang sejumlah kueri representatif yang merefleksikan kebutuhan eksplorasi informasi domain, kemudian mengeksekusinya pada basis data graf menggunakan bahasa query graf. Pendekatan perancangan kueri berbasis kebutuhan domain ini banyak digunakan dalam evaluasi knowledge graph, khususnya pada domain sejarah dan humaniora digital, untuk menguji apakah graf mampu menjawab pertanyaan relasional yang sebelumnya sulit dijawab menggunakan representasi dokumen biasa (Díaz et al., 2024; Graciotti, 2023). Dalam konteks penelitian ini, skenario kueri mencakup penelusuran tokoh yang terlibat dalam suatu peristiwa, pemetaan peristiwa berdasarkan lokasi, serta pengurutan peristiwa berdasarkan waktu.

Keberhasilan evaluasi dinilai secara kualitatif–deskriptif berdasarkan ketercapaian hasil kueri, konsistensi hubungan antar node, serta kesesuaian hasil dengan pengetahuan yang terkandung dalam teks sumber. Pendekatan ini sejalan dengan praktik evaluasi fungsional knowledge graph yang menilai kelayakan graf melalui kemampuan menjawab kueri relasional dan keterlacakan informasi, bukan melalui metrik numerik performa sistem (He et al., 2022; Xie et al., 2023). Selain itu, evaluasi juga mencakup pemeriksaan keterlacakan (*traceability*), yaitu kemampuan graf menautkan hasil kueri kembali ke sumber teks melalui metadata dokumen atau potongan teks, sebagaimana direkomendasikan pada penelitian konstruksi knowledge graph berbasis teks naratif (Díaz et al., 2024).


BAB 3

METODOLOGI

3.1 Metode dan Alur Kerja

Penelitian ini bertujuan membangun basis data graf Sirah Nabawiyah berbasis Named-Entity Recognition dengan memanfaatkan teknik pemrosesan bahasa alami. Sistem yang dikembangkan terdiri dari tahapan: preparasi dataset dari dokumen Sirah Nabawiyah, pembentukan dataset terstruktur, preprocessing untuk membersihkan noise (khususnya akibat OCR), chunking untuk membagi teks menjadi unit yang lebih kecil, manual labelling pada sebagian data sebagai seed, pseudo-labelling berbasis NER untuk memperluas entitas berlabel, pembentukan relasi antar entitas/peristiwa, serta konstruksi knowledge graph di Neo4j hingga menghasilkan output graf. Tahap akhir berupa pengujian dan evaluasi terbatas untuk memastikan konsistensi node–relationship dan memverifikasi bahwa graf dapat mendukung skenario penelusuran informasi relasional.

Alur sistem diawali dari dokumen Sirah Nabawiyah yang diproses pada tahap preparasi dataset (misalnya ekstraksi teks dan penyusunan struktur dokumen) hingga terbentuk dataset. Dataset kemudian melalui preprocessing data untuk menormalkan dan membersihkan teks agar siap diproses lebih lanjut. Setelah itu dilakukan chunking untuk membagi teks menjadi potongan yang lebih kecil, sehingga memudahkan proses anotasi maupun ekstraksi informasi. Pada sebagian chunk dipilih dilakukan manual labelling sebagai data acuan, kemudian diperluas melalui pseudo-labelling berbasis NER sehingga diperoleh entitas berlabel (PERSON, EVENT, LOCATION, dan TIME). Entitas berlabel ini selanjutnya digunakan pada tahap pembentukan relasi untuk menghasilkan relationship antar entitas/peristiwa. Hasil entitas dan relasi kemudian dikonstruksi menjadi knowledge graph di Neo4j dan menghasilkan output graf. Proses ditutup dengan pengujian dan evaluasi untuk memeriksa kualitas struktur graf serta memastikan hasilnya dapat ditelusuri menggunakan kueri sesuai kebutuhan penelitian. Diagram alir sistem secara umum ditampilkan pada Gambar 3.1.




Gambar 3.1 Diagram Alir Sistem

3.1.1 Preparasi Dataset

Tahap pertama dalam penelitian ini dilakukan ekstraksi teks dari dokumen Sirah Nabawiyah dalam format PDF (hasil scan) lalu menjadi teks digital per halamannya. Tahapan

ini juga bertujuan mengubah dokumen Sirah Nabawiyah menjadi dataset yang siap dipakai untuk tahapan selanjutnya. Secara garis besar, tahapan ini terbagi menjadi tiga tahapan utama : OCR tiap halaman, segmentasi konten berdasarkan struktur TOC, dan ekspor dataset ke CSV. Diagram alir tahap ini dapat dilihat pada gambar 3.2 di bawah ini :



Gambar 3.2 Diagram Alir Tahpan Preparasi Dataset

Tahapan pertama adalah melakukan OCR pada tiap halaman dalam buku Sirah Nabawiyah. Proses dimulai dengan mengonversi tiap halaman PDF menjadi citra per halaman agar bisa diproses oleh mesin OCR. Untuk meningkatkan kualitas pembacaan, citra hasil konversi kemudian melalui praproses sederhana seperti penyesuaian resolusi/ukuran, reduksi *noise*, dan peningkatan kontras, sehingga karakter lebih jelas dan kesalahan pembacaan dapat diminimalkan. OCR yang digunakan dalam penelitian ini adalah PaddleOCR dengan konfigurasi bahasa Indonesia untuk mengekstraksi teks dari tiap halaman. Sistem memproses halaman secara berurutan, kemudian hasil pengenalan karakter disusun kembali menjadi teks dan disimpan sebagai berkas .txt per halaman. Hasil dari tahap pertama ini adalah kumpulan teks mentah hasil OCR tiap halaman dengan format *page_nomor-halaman.txt* (misalnya *page_001.txt*, *page_002.txt*, dst.). Tabel 3.1 dibawah menunjukkan contoh hasil OCR untuk beberapa halaman tertentu.

Tabel 3.1 Hasil OCR Sirah Nabawiyah

Nama File	Hasil OCR
<i>page_034.txt</i>	POSISI BANGSA ARAB DAN KAUMNYA ADA hakikatnya istilah Sirah Nabawiyah merupakan ungkapan tentang risalah yang dibawa Rasulullah @ kepada manusia, untuk mengeluarkan mereka dari kegelapan kepada cahaya, dari penyembahan terhadap hamba kepada penyembahan Allah. Jadi tidak mungkin bisa menghadirkan gambarannya secara pas dan mengena kecuali setelah membandingkan hal-hal di balik risalah ini dan pengaruhnya. Berangkat dari sinilah kami merasa perlu mengemukakan sedikit uraian tentang kaum-kaum bangsa Arab dan perkembangannya sebelum Islam, serta tentang kondisi-kondisi saat beliau diutus sebagai rasul

	Posisi Bangsa Arab ... bebas dari segala urusan semenjak zaman dahulu. Sekalipun begitu mereka Sirah Nabawiyah 1
<i>page_038.txt</i>	Beberapa hari kemudian, bekal dan air sudah habis. Sementara tidak ada mata air yang mengalir. Tiba-tiba mata air Zamzam memancar berkat karunia Allah ... Allah @ telah menyebutkan di dalam Al-Qur an, bahwa Ibrahim bermimp selagi tidur, bahwa beliau menyembelih anaknya, Isma'il. Maka dari itu beliau bangun dan hendak melaksanakan mimpi yang dianggap sebagai sebuah perintah. W n1 pHI 3 I EL O} 8s wJI s2 &Ku TJI t1.y-1.r :ebaI W KK "Tatkala keduanya telah berserah diri dan Ibrahim membaringkan anaknya ... Lihat Shahihul-Bukhari, Kitabul-Anbiya, 1/474-475 4 Ibid,1/475 Sirah Nabawiyah 5

Berdasarkan hasil OCR tersebut didapati masih terdapat beberapa karakter yang tidak bisa dibaca dengan jelas oleh OCR sehingga menghasilkan susunan / penggalan kata yang tidak jelas. Lalu dibagian akhir selalu terdapat *footer* yang terdeteksi dengan tulisan "Sirah Nabawiyah" dan "nomor halaman" (seperti 1, 5, dll).

Langkah berikutnya, kumpulan teks hasil OCR per halaman disusun kembali mengikuti struktur dokumen berdasarkan acuan daftar isi (*Table of Contents/TOC*). Pada tahap ini, teks dikelompokkan ke dalam bab dan sub-bab yang sesuai melalui pencocokan judul menggunakan kombinasi *exact matching* dan *fuzzy matching*. Selain itu, dilakukan pembersihan bagian footer yang berulang muncul pada halaman, seperti teks "Sirah Nabawiyah" dan nomor halaman, agar tidak mengganggu proses pengelompokan. Isi teks yang berada pada sub-bab yang sama kemudian digabung menjadi satu string sehingga representasi teks tidak terpecah per baris, lalu disimpan dalam format JSON sebagai dokumen terstruktur. Tahapan terakhir adalah mengonversi dokumen terstruktur tersebut ke format CSV untuk membentuk dataset akhir, dengan struktur kolom sebagaimana ditunjukkan pada Tabel


Tabel 3.2 Struktur Dataset Sirah Nabawiyah

Nama Kolom	Tipe Data	Deskripsi	Contoh Nilai
------------	-----------	-----------	--------------

judul_bab	String (text)	Nama bab utama hasil segmentasi berdasarkan TOC.	POSISI BANGSA ARAB DAN KAUMNYA
judul_sub_bab	String (text)	Nama sub-bab yang berada di bawah bab terkait, hasil pencocokan TOC	Posisi Bangsa Arab
halaman	String (text)	Informasi halaman sumber konten sub-bab. Ditulis sebagai nomor tunggal atau rentang (mis. 21-24) dan dapat memuat gabungan beberapa rentang (mis. 21-24, 26, 30-32).	34-35
teks	String (text)	Isi teks sub-bab yang telah dibersihkan (footer/header berulang) dan digabung menjadi satu string.	Menurut bahasa, Arab artinya padang pasir, tanah gundul, dan gersang yang tiada air dan tanamannya. ...

3.1.2 Preprocessing Data

Pada tahap *preprocessing*, dataset dalam format CSV dibersihkan untuk mengurangi *noise* hasil OCR dan menyiapkan teks agar lebih stabil pada tahap ekstraksi entitas maupun relasi. Diagram alir tahapan ini ditunjukkan pada gambar 3.3




Gambar 3.3 Diagram Alir Tahapan Preprocessing Data

Proses diawali dengan menyaring baris yang tidak relevan, seperti bagian “UNKNOWN BAB” dan bibliografi, karena tidak termasuk konten utama yang dianalisis. Selanjutnya dilakukan normalisasi teks dengan menghapus karakter non-printing, merapikan spasi, serta menghilangkan simbol-simbol non-informatif yang sering muncul pada hasil OCR. Setelah itu,

dilakukan pembersihan *gibberish*, yaitu menghapus token atau kalimat yang tidak jelas/tidak bermakna akibat kesalahan OCR. Hasil akhir dari tahap ini berupa teks yang lebih bersih dan konsisten sehingga siap diproses pada tahap berikutnya.

3.1.3 Chunking

Tahap chunking bertujuan untuk membagi teks pada setiap sub-bab menjadi potongan-potongan (chunks) yang lebih kecil namun tetap mempertahankan konteks. Pemecahan ini diperlukan karena teks per sub-bab dapat berukuran panjang sehingga kurang efisien untuk proses anotasi manual maupun pemrosesan NER. Diagram alir tahapan ini ditunjukkan pada gambar 3.4



Gambar 3.4 Diagram Alir Tahapan Chunking


Proses chunking diawali dengan segmentasi kalimat, yaitu memecah teks menjadi kalimat-kalimat individual berdasarkan tanda baca akhir kalimat seperti tanda titik, tanda tanya, dan tanda seru. Segmentasi berbasis kalimat dipilih untuk memastikan setiap chunk tidak terpotong di tengah kalimat sehingga konteks tetap terjaga.

Setelah segmentasi, beberapa kalimat digabungkan menjadi satu chunk dengan batas maksimum panjang 1500 karakter. Penggabungan dilakukan secara berurutan hingga mencapai batas maksimum, kemudian chunk baru dimulai. Untuk menjaga kesinambungan konteks antar chunk, diterapkan mekanisme overlap di mana satu kalimat terakhir dari chunk sebelumnya diulang pada chunk berikutnya. Overlap ini membantu mempertahankan konteks entitas yang mungkin terpecah antar chunk.

Setiap chunk diberi identitas unik dan metadata untuk memudahkan pelacakan ke sumber asli. Metadata yang disimpan meliputi `chunk_id` sebagai identitas unik setiap chunk, `doc_id` sebagai identitas dokumen asal, `chunk_index` sebagai urutan chunk dalam dokumen, serta `judul_bab`, `judul_sub_bab`, dan `halaman` sebagai informasi sumber. Hasil chunking diekspor ke dalam file CSV baru yang siap digunakan pada tahap manual labelling.

3.1.4 Manual Labelling

Tahap manual labelling bertujuan untuk membentuk data anotasi yang akan digunakan sebagai seed untuk pseudo-labelling dan sebagai ground truth untuk evaluasi. Proses anotasi dilakukan secara manual oleh peneliti dengan menandai entitas dalam teks sesuai skema label yang telah ditentukan. Diagram alir tahapan ini ditunjukkan pada gambar 3.5



Gambar 3.5 Diagram Alir Tahapan Manual Labelling


Proses manual labelling diawali dengan sampling data dari hasil chunking. Pemilihan sampel dilakukan dengan strategi pengambilan per bab untuk menghindari dominasi bab tertentu, dengan maksimal 25 chunk per bab diambil sebagai sampel. Random seed digunakan untuk memastikan konsistensi dan reproduksibilitas pemilihan sampel. Template anotasi disiapkan dalam format spreadsheet dengan kolom metadata chunk (`chunk_id`, `judul_bab`, `judul_sub_bab`, `halaman`), `teks_chunk`, `entity_text`, dan `label`.

Proses anotasi dilakukan dengan membaca setiap chunk dan mengidentifikasi entitas sesuai skema label yang telah ditentukan. Label `PERSON` digunakan untuk nama tokoh atau individu seperti Abu Bakar, Rasulullah, dan Khadijah. Label `EVENT` digunakan untuk nama peristiwa seperti Perang Badar, Hijrah, dan Fathu Makkah. Label `LOCATION` digunakan untuk nama lokasi geografis seperti Mekah, Madinah, dan Gua Hira. Label `TIME` digunakan untuk informasi waktu atau periode seperti tahun ke-2 Hijriah dan bulan Ramadhan.

Setelah anotasi selesai, data hasil anotasi dibagi menjadi dua bagian yang tidak tumpang tindih. Sebesar 70% data digunakan sebagai data seed yang menjadi acuan dalam proses pseudo-labelling, sedangkan 30% sisanya disimpan terpisah sebagai data ground truth yang khusus digunakan untuk evaluasi. Pemisahan ini penting untuk menjaga validitas evaluasi karena data ground truth tidak boleh digunakan saat proses pseudo-labelling. Tahap terakhir adalah validasi hasil anotasi untuk memastikan konsistensi pelabelan, tidak ada entitas penting yang terlewat, dan kebenaran label yang diberikan.

3.1.5 Pseudo-labelling berbasis NER

Tahap pseudo-labelling bertujuan untuk memperluas cakupan anotasi entitas dari data seed ke seluruh data yang belum berlabel. Proses ini dilakukan menggunakan dua skenario ekstraksi yang berbeda: SRL-based NER dan LLM-based NER. Kedua skenario dijalankan secara paralel untuk menghasilkan dua set entitas berlabel yang akan dibandingkan performanya. Diagram alir tahap pseudo-labelling ditunjukkan pada Gambar 3.6.



Gambar 3.6 Diagram Alir Tahapan Pseudo-labelling NER dengan 2 Skenario


Proses pseudo-labelling diawali dengan persiapan data input yang terdiri dari data seed sebagai referensi dan data yang belum berlabel. Selanjutnya, ekstraksi entitas dilakukan menggunakan dua skenario secara paralel.

Skenario pertama adalah SRL-based NER yang memanfaatkan pendekatan Semantic Role Labeling. Proses dimulai dengan parsing dependensi dan SRL untuk mengidentifikasi predikat (kata kerja) sebagai pusat peristiwa dan mengekstraksi argumen semantik. Hasil parsing kemudian dipetakan ke label entitas di mana ARG0 (pelaku/agent) dipetakan ke kandidat PERSON, ARGM-LOC (lokasi) dipetakan ke kandidat LOCATION, ARGM-TMP (waktu) dipetakan ke kandidat TIME, dan predikat yang merupakan peristiwa penting dipetakan ke kandidat EVENT. Kandidat entitas kemudian divalidasi dan difilter berdasarkan pola linguistik dan aturan domain untuk meningkatkan presisi.

Skenario kedua adalah LLM-based NER yang memanfaatkan Large Language Model. Proses dimulai dengan perancangan prompt yang mendefinisikan skema label, menyertakan contoh dari data seed (*few-shot learning*), dan menentukan format output terstruktur dalam bentuk JSON. Setiap chunk beserta prompt dikirimkan ke LLM API, dan respons dalam format JSON yang berisi daftar entitas diterima. Output dari LLM kemudian di-parsing dan divalidasi untuk memastikan format dan kelengkapan sesuai dengan skema yang ditentukan. Hasil ekstraksi dari kedua skenario kemudian dinormalisasi dengan menyeragamkan format penulisan entitas, menghapus duplikasi dalam satu chunk, dan memetakan variasi penulisan ke bentuk kanonik. Hasil akhir disimpan dalam dua file terpisah berdasarkan skenario yang digunakan.

3.1.6 Pembentukan Relasi

Tahap pembentukan relasi bertujuan untuk menghubungkan entitas yang telah diekstraksi menjadi pasangan node-edge sehingga terbentuk struktur pengetahuan yang dapat dimasukkan ke basis data graf. Proses ini dilakukan pada hasil ekstraksi dari kedua skenario secara terpisah. Diagram alir tahap pembentukan relasi ditunjukkan pada Gambar 3.7.




Gambar 3.7 Diagram Alir Tahapan Pembentukan Relasi

Proses pembentukan relasi diawali dengan identifikasi kandidat pasangan entitas yang berpotensi memiliki relasi. Pasangan entitas diidentifikasi berdasarkan kemunculan dalam chunk yang sama dan kedekatan posisi dalam teks. Entitas bertipe EVENT diprioritaskan sebagai penghubung karena dalam domain Sirah, peristiwa menjadi pusat keterhubungan antara tokoh, lokasi, dan waktu. Penentuan tipe relasi dilakukan berdasarkan kombinasi label entitas yang membentuk pasangan. Pasangan PERSON dan EVENT menghasilkan relasi INVOLVED_IN yang menunjukkan keterlibatan tokoh dalam peristiwa. Pasangan EVENT dan LOCATION menghasilkan relasi OCCURRED_AT yang menunjukkan lokasi terjadinya peristiwa. Pasangan EVENT dan TIME menghasilkan relasi OCCURRED_ON yang menunjukkan waktu terjadinya peristiwa.

Ekstraksi relasi dari konteks dilakukan dengan menganalisis struktur kalimat untuk mengkonfirmasi relasi, menggunakan kata kunci pemicu relasi seperti "di", "pada", "ketika", dan "terlibat", serta memvalidasi relasi dengan konteks semantik. Setiap relasi yang diekstraksi dilengkapi dengan informasi provenance untuk memungkinkan pelacakan kembali ke sumber. Tahap terakhir adalah deduplikasi dan normalisasi relasi dengan menggabungkan relasi yang sama dari konteks berbeda, memetakan entitas ke bentuk kanonik, dan menghapus relasi duplikat. Hasil akhir diekspor dalam format edge list sesuai skenario yang digunakan.

3.1.7 Konstruksi Knowledge Graph di Neo4j

Tahap konstruksi knowledge graph bertujuan untuk membangun basis data graf di Neo4j berdasarkan entitas dan relasi yang telah diekstraksi. Proses ini menghasilkan dua graf terpisah: Graf A dari hasil SRL-based NER dan Graf B dari hasil LLM-based NER. Diagram alir tahap konstruksi knowledge graph ditunjukkan pada Gambar 3.8.



Gambar 3.8 Diagram Alir Pembuatan Knowledge Graph menggunakan Neo4j

Proses konstruksi diawali dengan perancangan skema graf yang mendefinisikan struktur data dalam Neo4j. Skema graf terdiri dari empat label node yaitu Person untuk entitas tokoh, Event untuk entitas peristiwa, Location untuk entitas lokasi, dan Time untuk entitas waktu. Tiga tipe relationship didefinisikan yaitu INVOLVED_IN yang menghubungkan Person ke Event, OCCURRED_AT yang menghubungkan Event ke Location, dan OCCURRED_ON yang menghubungkan Event ke Time. Setiap node memiliki properti name untuk nama entitas dalam bentuk kanonik, aliases untuk variasi nama atau sebutan lain, dan source_chunks untuk daftar chunk_id sumber. Setelah skema dirancang, dilakukan inisialisasi database Neo4j dengan membuat database baru untuk masing-masing graf dan mengatur konfigurasi koneksi. Constraint dan index kemudian dibuat untuk mencegah duplikasi node dan mengoptimasi kueri. Uniqueness constraint diterapkan pada properti name untuk setiap label node sehingga tidak ada dua node dengan nama yang sama dalam satu label.

Proses import node dilakukan dengan membaca file entitas dan membuat node dengan label sesuai tipe entitas. Perintah MERGE digunakan untuk menghindari duplikasi di mana node baru dibuat jika belum ada, atau properti diperbarui jika node sudah ada. Setelah semua node dibuat, proses import relationship dilakukan dengan membaca file relasi, mencocokkan source dan target node berdasarkan nama, dan membuat relationship dengan tipe yang sesuai. Setiap relationship dilengkapi dengan properti evidence dan chunk_ids untuk menyimpan informasi provenance. Tahap terakhir adalah validasi graf untuk memastikan konstruksi berhasil. Validasi meliputi pemeriksaan jumlah node per label, pemeriksaan jumlah relationship per tipe, pengujian kueri sederhana untuk memastikan graf dapat diakses, dan verifikasi tidak ada orphan node (node tanpa relationship). Output dari tahap ini adalah dua basis data graf Neo4j yang siap untuk pengujian dan evaluasi.

3.1.8 Pengujian dan Evaluasi

Tahap pengujian dan evaluasi bertujuan untuk memvalidasi kualitas hasil ekstraksi entitas serta memverifikasi kelayakan struktur basis data graf dalam mendukung penelusuran informasi relasional pada domain Sirah Nabawiyah. Evaluasi dalam penelitian ini terbagi menjadi dua bagian utama, yaitu evaluasi hasil *Named Entity Recognition* (NER) untuk mengukur performa kedua skenario ekstraksi, serta evaluasi fungsional basis data graf untuk memastikan graf yang dibangun dapat menjawab kebutuhan kueri relasional. Desain evaluasi secara keseluruhan ditunjukkan pada Tabel 3.3

Tabel 3.3 Ringkasan Desain Evaluasi

Aspek Evaluasi	Metode	Metrik / Output
Kualitas Ekstraksi NER	Perbandingan prediksi vs ground truth	<i>Precision, Recall, F1-score</i> per label dan agregat
Kualitas Graf	Pengujian kueri Cypher + perbandingan struktur	Tingkat keberhasilan kueri, statistik node/edge

3.1.8.1 Evaluasi Hasil Named Entity Recognition

Evaluasi *Named Entity Recognition* (NER) bertujuan untuk mengukur kemampuan kedua skenario ekstraksi, yaitu *SRL-based* NER dan *LLM-based* NER, dalam mengenali dan mengklasifikasikan entitas dari teks Sirah Nabawiyah. Evaluasi ini dilakukan dengan membandingkan hasil prediksi entitas terhadap data acuan (*ground truth*) yang telah dianotasi secara manual. Selain mengukur performa masing-masing skenario, evaluasi juga bertujuan

untuk membandingkan kedua pendekatan guna mengidentifikasi kelebihan dan kekurangan masing-masing metode dalam konteks domain Sirah.

Untuk menjaga validitas evaluasi, data hasil manual labelling dibagi menjadi dua bagian yang tidak saling tumpang tindih. Bagian pertama sebesar 70% digunakan sebagai data *seed* dalam proses *pseudo-labelling*, sedangkan bagian kedua sebesar 30% disimpan terpisah sebagai data uji (*ground truth*) yang secara khusus digunakan untuk evaluasi performa. Pemisahan ini penting untuk memastikan bahwa data yang digunakan untuk mengukur performa tidak pernah dilihat oleh model selama proses ekstraksi, sehingga hasil evaluasi mencerminkan kemampuan generalisasi model secara objektif.

Proses evaluasi NER dilakukan melalui beberapa langkah sebagai berikut. Langkah pertama adalah persiapan data uji, yaitu memisahkan sebagian data hasil *manual labelling* sebagai *ground truth* dan memastikan distribusi label yang representatif mencakup keempat tipe entitas (*PERSON*, *EVENT*, *LOCATION*, dan *TIME*). Langkah kedua adalah eksekusi ekstraksi pada data uji, di mana kedua skenario (*SRL-based NER* dan *LLM-based NER*) dijalankan pada data uji yang sama untuk menghasilkan prediksi entitas. Penggunaan data uji yang identik bertujuan untuk memastikan perbandingan yang adil antara kedua metode.

Langkah ketiga adalah pencocokan hasil prediksi dengan *ground truth*. Pada tahap ini, entitas hasil prediksi dibandingkan dengan entitas pada *ground truth* menggunakan kriteria *exact match*, di mana teks entitas dan label harus sama persis agar dianggap sebagai prediksi yang benar. Berdasarkan hasil pencocokan, setiap prediksi dikategorikan ke dalam tiga kelompok: *True Positive* (TP) untuk entitas yang diprediksi dengan benar, *False Positive* (FP) untuk entitas yang diprediksi tetapi tidak sesuai dengan *ground truth*, dan *False Negative* (FN) untuk entitas yang ada di *ground truth* tetapi tidak berhasil diprediksi.

Langkah keempat adalah perhitungan metrik evaluasi. Metrik yang digunakan meliputi *Precision*, *Recall*, dan *F1-score* yang dihitung untuk setiap label entitas (*PERSON*, *EVENT*, *LOCATION*, *TIME*) serta secara agregat menggunakan *Macro-average F1-score*. *Precision* mengukur proporsi prediksi yang benar dari seluruh prediksi yang dihasilkan, *Recall* mengukur proporsi entitas yang berhasil ditemukan dari seluruh entitas yang seharusnya ada, sedangkan *F1-score* merupakan rata-rata harmonik dari *Precision* dan *Recall* yang memberikan ukuran keseimbangan antara keduanya. Perhitungan metrik evaluasi menggunakan rumus yang telah dijelaskan pada Bab 2.

Langkah terakhir adalah analisis perbandingan, yaitu membandingkan performa *SRL-based NER* dengan *LLM-based NER* berdasarkan metrik yang diperoleh. Analisis ini mencakup identifikasi label mana yang paling mudah atau sulit diekstraksi oleh masing-masing metode, serta pola kesalahan yang sering terjadi seperti entitas yang terlewat atau salah klasifikasi label. Output dari evaluasi NER berupa tabel perbandingan metrik kedua skenario per label, metrik agregat, serta analisis kualitatif mengenai karakteristik performa masing-masing pendekatan.

3.1.8.2 Evaluasi Fungsional Basis Data Graf

Evaluasi fungsional basis data graf bertujuan untuk memverifikasi bahwa struktur graf yang dibangun dapat mendukung penelusuran informasi relasional pada domain Sirah Nabawiyah. Mengingat penelitian ini menghasilkan dua graf terpisah dari kedua skenario ekstraksi, evaluasi juga bertujuan untuk membandingkan kelayakan graf hasil *SRL-based NER*

(Graf A) dan graf hasil LLM-based NER (Graf B) dalam menjawab kueri relasional yang merepresentasikan kebutuhan eksplorasi informasi pada kajian Sirah.

Evaluasi fungsional dilakukan melalui pendekatan pengujian berbasis skenario kueri (*query-based functional testing*). Pendekatan ini dipilih karena tujuan utama konstruksi graf adalah untuk mendukung penelusuran informasi berbasis relasi, sehingga kemampuan graf dalam menjawab kueri menjadi indikator utama kelayakannya. Evaluasi mencakup perancangan kueri, eksekusi kueri pada kedua graf, verifikasi hasil, serta perbandingan struktur graf.

Langkah pertama adalah perancangan skenario kueri. Kueri Cypher dirancang untuk merepresentasikan berbagai kebutuhan penelusuran informasi pada domain Sirah Nabawiyah, mencakup kueri berbasis tokoh, lokasi, waktu, serta kueri multi-hop yang melibatkan lebih dari satu pola relasi. Rancangan skenario kueri yang akan digunakan dalam evaluasi ditunjukkan pada Tabel 3.Y.

Langkah kedua adalah eksekusi kueri pada kedua graf. Setiap kueri Cypher yang telah dirancang dijalankan pada Graf A (hasil SRL-based NER) dan Graf B (hasil LLM-based NER). Hasil yang dikembalikan oleh masing-masing graf dicatat untuk analisis lebih lanjut, termasuk jumlah node yang dikembalikan dan waktu eksekusi kueri.

Langkah ketiga adalah verifikasi hasil kueri. Verifikasi dilakukan untuk memastikan kebenaran dan kelayakan hasil kueri melalui beberapa kriteria: (1) kueri dapat dieksekusi tanpa error, (2) hasil kueri tidak kosong yang menunjukkan graf memiliki data relevan, (3) hasil kueri sesuai dengan fakta yang terdapat dalam teks sumber Sirah Nabawiyah melalui validasi manual, dan (4) hasil kueri dapat dilacak kembali ke dokumen sumber (traceability) melalui metadata yang disimpan pada node atau relationship.

Langkah keempat adalah perbandingan struktur graf. Selain evaluasi berbasis kueri, dilakukan juga perbandingan statistik struktur antara Graf A dan Graf B. Perbandingan mencakup jumlah node per label (*Person, Event, Location, Time*) dan jumlah relationship per tipe (*INVOLVED_IN, OCCURRED_AT, OCCURRED_ON*). Perbandingan ini bertujuan untuk mengidentifikasi perbedaan cakupan informasi yang berhasil diekstraksi oleh masing-masing skenario.

Output dari evaluasi fungsional graf meliputi tabel hasil eksekusi kueri untuk kedua graf yang mencakup status keberhasilan dan jumlah hasil, tabel perbandingan statistik struktur graf, contoh hasil kueri dari masing-masing graf sebagai ilustrasi, serta analisis perbandingan kelayakan Graf A dan Graf B dalam mendukung penelusuran informasi relasional pada domain Sirah Nabawiyah.

3.2 Spesifikasi Lingkungan

Pada penelitian ini, seluruh tahapan implementasi—mulai dari ekstraksi teks berbasis OCR, penyusunan dataset, prapemrosesan, chunking, hingga persiapan konstruksi *knowledge graph*—dijalankan pada lingkungan komputasi yang terdefinisi agar proses dapat direplikasi dan hasil tiap tahap dapat ditelusuri kembali. Oleh karena itu, bagian ini menjelaskan spesifikasi lingkungan yang digunakan, mencakup perangkat keras dan perangkat lunak beserta konfigurasi penting yang berpengaruh terhadap jalannya eksperimen, seperti kebutuhan komputasi, kompatibilitas pustaka, serta konsistensi keluaran pada setiap tahap.

3.2.1 Perangkat Keras

Eksperimen komputasi pada penelitian ini dijalankan pada lingkungan perangkat keras komputer lokal sebagai media utama pengolahan data, mulai dari ekstraksi teks berbasis OCR, penyusunan dataset, prapemrosesan, chunking, hingga proses anotasi manual dan persiapan integrasi ke Neo4j. Seluruh proses dilakukan secara terstruktur agar setiap keluaran tahap dapat terdokumentasi dan mudah ditelusuri kembali. Spesifikasi perangkat yang digunakan adalah sebagai berikut: prosesor CPU Intel(R) Core(TM) i7-8750H @ 2.20GHz, RAM 16 GB, serta penyimpanan 1 TB. Pada implementasi OCR (PaddleOCR), pemrosesan dapat berjalan pada CPU, sehingga kebutuhan GPU bersifat opsional dan lebih relevan apabila pada tahap lanjutan dilakukan eksperimen model berbasis deep learning/LLM.

3.2.2 Perangkat Lunak

Seluruh proses penelitian diimplementasikan menggunakan bahasa pemrograman Python pada lingkungan Jupyter Notebook untuk memudahkan eksperimen bertahap dan pencatatan keluaran tiap modul. Ekstraksi teks dilakukan menggunakan PaddleOCR dengan konfigurasi bahasa Indonesia, sedangkan konversi PDF ke citra dilakukan menggunakan library pdf2image dengan dukungan Poppler. Pengolahan data tabular dan manipulasi dataset dilakukan menggunakan library pandas dan numpy, sementara proses utilitas memanfaatkan library tqdm untuk progress monitoring dan modul regex untuk pemrosesan string.

Untuk konstruksi knowledge graph, penelitian ini menggunakan Neo4j Desktop 2.1.1 sebagai DBMS graf, serta bahasa kueri Cypher untuk validasi dan pengujian skenario eksplorasi graf. Seluruh keluaran seperti hasil OCR per halaman, dokumen terstruktur JSON, dataset CSV chunking, dan hasil anotasi disimpan dalam format berkas terpisah agar alur kerja dapat direplikasi dan dievaluasi kembali.

3.3 Rencana Implementasi

Rancangan implementasi dijelaskan melalui pseudocode berikut yang merepresentasikan alur kerja utama dari setiap komponen sistem.

3.3.1 Implementasi Pseudo-labelling menggunakan SRL-Based NER

Kode Semu 3.1 di bawah ini menunjukkan alur kerja ekstraksi entitas menggunakan pendekatan Semantic Role Labeling.

```
INPUT : chunks_dataset (CSV berisi chunk teks)
OUTPUT : entities_srl (CSV berisi entitas hasil ekstraksi SRL)
```

ALGORITMA:

```
1. BEGIN
2.   // Inisialisasi NLP pipeline
3.   nlp_pipeline ← InitializeStanzaPipeline(lang="id")
4.   entities_srl ← []
5.
6.   FOR EACH chunk IN chunks_dataset DO
7.     chunk_text ← chunk.teks_chunk
8.     doc ← nlp_pipeline.Process(chunk_text)
9.
10.    FOR EACH sentence IN doc.sentences DO
11.      predicates ← GetPredicates(sentence)
12.
13.      FOR EACH predicate IN predicates DO
14.        srl_result ← ExtractSemanticRoles(sentence, predicate)
```

```

15.
16.         // ARG0 (pelaku) → PERSON
17.         IF srl_result.ARG0 EXISTS THEN
18.             candidate ← srl_result.ARG0.text
19.             IF IsValidPersonName(candidate) THEN
20.                 entities_srl.APPEND({
21.                     chunk_id: chunk.chunk_id,
22.                     entity_text: candidate,
23.                     label: "PERSON",
24.                     start_pos: srl_result.ARG0.start,
25.                     end_pos: srl_result.ARG0.end
26.                 })
27.             END IF
28.         END IF
29.
30.         // ARGM-LOC (lokasi) → LOCATION
31.         IF srl_result.ARGM_LOC EXISTS THEN
32.             candidate ← srl_result.ARGM_LOC.text
33.             IF IsValidLocation(candidate) THEN
34.                 entities_srl.APPEND({
35.                     chunk_id: chunk.chunk_id,
36.                     entity_text: candidate,
37.                     label: "LOCATION",
38.                     start_pos: srl_result.ARGM_LOC.start,
39.                     end_pos: srl_result.ARGM_LOC.end
40.                 })
41.             END IF
42.         END IF
43.
44.         // ARGM-TMP (waktu) → TIME
45.         IF srl_result.ARGM_TMP EXISTS THEN
46.             candidate ← srl_result.ARGM_TMP.text
47.             entities_srl.APPEND({
48.                 chunk_id: chunk.chunk_id,
49.                 entity_text: candidate,
50.                 label: "TIME",
51.                 start_pos: srl_result.ARGM_TMP.start,
52.                 end_pos: srl_result.ARGM_TMP.end
53.             })
54.         END IF
55.
56.         // Predicate → EVENT
57.         event_candidate ← ExtractEventPhrase(sentence, predicate)
58.         IF IsValidEvent(event_candidate) THEN
59.             entities_srl.APPEND({
60.                 chunk_id: chunk.chunk_id,
61.                 entity_text: event_candidate,
62.                 label: "EVENT",
63.                 start_pos: predicate.start,
64.                 end_pos: predicate.end
65.             })
66.         END IF
67.     END FOR
68. END FOR
69. END FOR
70.
71. // Normalisasi dan deduplikasi
72. entities_srl ← NormalizeEntities(entities_srl)
73. entities_srl ← RemoveDuplicates(entities_srl)

```

```
74.  
75.     SaveCSV(entities_srl, "entities_srl.csv")  
76.     RETURN entities_srl  
77. END
```

Kode Semu 3.1 Alur Kerja SRL NER

Langkah pertama dimulai pada baris 1–4, yaitu melakukan inisialisasi komponen yang diperlukan untuk ekstraksi entitas. Pada tahap ini, sistem menyiapkan *pipeline* NLP berbahasa Indonesia menggunakan Stanza, sebuah library pemrosesan bahasa alami yang mendukung analisis linguistik mendalam seperti tokenisasi, *part-of-speech tagging*, *dependency parsing*, dan *semantic role labeling*. Selain itu, dibuat sebuah list kosong bernama `entities_srl` yang akan menampung seluruh entitas yang berhasil diekstraksi dari teks. Inisialisasi *pipeline* ini penting karena menjadi fondasi bagi seluruh proses analisis semantik yang akan dilakukan pada tahapan selanjutnya.

Baris 6–8 bertujuan untuk melakukan iterasi pada setiap chunk teks yang terdapat dalam dataset. Setiap chunk diambil dari kolom `teks_chunk` dan kemudian diproses menggunakan *pipeline* NLP yang telah diinisialisasi sebelumnya. Proses ini menghasilkan objek dokumen (`doc`) yang berisi struktur linguistik lengkap dari teks, termasuk segmentasi kalimat, analisis kata, dan struktur sintaksis. Pemrosesan per chunk dilakukan untuk menjaga efisiensi komputasi dan memastikan setiap potongan teks dapat dianalisis secara menyeluruh tanpa kehilangan konteks penting yang diperlukan untuk ekstraksi entitas.

Selanjutnya, baris 10–14 melakukan analisis predikat sebagai pusat struktur semantik kalimat. Pada tahap ini, sistem melakukan iterasi pada setiap kalimat dalam dokumen untuk mengidentifikasi predikat, yaitu kata kerja yang menjadi pusat kejadian atau peristiwa dalam kalimat. Setelah predikat ditemukan, dilakukan ekstraksi *semantic roles* yang mengidentifikasi peran semantik dari setiap elemen kalimat terhadap predikat tersebut. Dalam konteks Sirah Nabawiyah, predikat seringkali merepresentasikan peristiwa penting, sedangkan argumen-argumennya menunjukkan pelaku (siapa), lokasi (di mana), dan waktu (kapan) peristiwa tersebut terjadi. Tahapan ini menjadi kunci utama dalam pendekatan SRL-based NER karena struktur semantik inilah yang akan dipetakan menjadi entitas berlabel.

Baris 16–28 berfokus pada ekstraksi entitas bertipe *PERSON* dari argumen ARG0. Dalam kerangka *semantic role labeling*, ARG0 umumnya merepresentasikan pelaku atau agen dari suatu tindakan. Sistem mengecek apakah pada hasil SRL terdapat ARG0, dan jika ada, teks dari argumen tersebut diambil sebagai kandidat entitas. Kandidat kemudian divalidasi menggunakan fungsi `IsValidPersonName` yang memeriksa apakah teks tersebut memenuhi kriteria nama tokoh, misalnya diawali huruf kapital atau sesuai pola nama dalam konteks Sirah. Jika valid, kandidat tersebut disimpan sebagai entitas bertipe *PERSON* lengkap dengan informasi metadata seperti `chunk_id`, posisi awal dan akhir span teks, serta label. Contohnya, dalam kalimat "Abu Bakar pergi ke Mekah", "Abu Bakar" akan teridentifikasi sebagai ARG0 dan disimpan sebagai entitas *PERSON*.

Pada baris 30–42, dilakukan ekstraksi entitas bertipe *LOCATION* dari argumen ARGM-LOC. Argumen ini merepresentasikan keterangan lokasi dalam struktur semantik kalimat, menunjukkan di mana suatu peristiwa terjadi. Proses yang dilakukan serupa dengan ekstraksi *PERSON*, yaitu mengecek keberadaan ARGM-LOC, mengambil teks kandidat, dan memvalidasi apakah teks tersebut merupakan nama lokasi yang valid menggunakan fungsi `IsValidLocation`. Validasi dapat mencakup pengecekan pola geografis atau pencocokan

dengan daftar lokasi yang dikenal dalam konteks Sirah Nabawiyah seperti Mekah, Madinah, atau nama-nama tempat lain yang relevan. Entitas yang lolos validasi kemudian disimpan dengan label *LOCATION* beserta informasi posisi dan sumber chunk-nya.

Baris 44–54 bertujuan untuk mengekstraksi entitas bertipe *TIME* dari argumen ARGUMENT. Argumen ini menandai keterangan waktu yang terkait dengan predikat, seperti "pada tahun ke-2 Hijriah", "bulan Ramadhan", atau "ketika malam hari". Berbeda dengan ekstraksi *PERSON* dan *LOCATION*, ekstraksi *TIME* tidak selalu memerlukan validasi ketat karena ekspresi temporal cenderung memiliki pola yang lebih jelas. Setiap kandidat waktu yang teridentifikasi langsung disimpan sebagai entitas *TIME* dengan informasi metadata lengkap. Identifikasi entitas waktu ini sangat penting dalam konstruksi knowledge graph karena memungkinkan pembentukan timeline peristiwa dan hubungan kronologis antar-kejadian dalam Sirah Nabawiyah.

Tahap berikutnya pada baris 56–66 melakukan ekstraksi entitas bertipe *EVENT* berdasarkan predikat yang teridentifikasi. Sistem mengekstrak frasa peristiwa yang mencakup predikat beserta konteks sekitarnya menggunakan fungsi `ExtractEventPhrase`. Tidak semua predikat dianggap sebagai *EVENT*; hanya yang memenuhi kriteria peristiwa penting dalam konteks Sirah yang disimpan, misalnya "Hijrah ke Madinah", "Perang Badar", atau "Fathu Makkah". Validasi dilakukan melalui fungsi `IsValidEvent` yang dapat memanfaatkan daftar peristiwa kunci atau pola linguistik tertentu. Entitas *EVENT* menjadi node sentral dalam knowledge graph karena menghubungkan berbagai entitas lain seperti tokoh yang terlibat, lokasi kejadian, dan waktu terjadinya peristiwa.

Proses dilanjutkan pada baris 71–73 dengan tahap post-processing yang meliputi normalisasi dan deduplikasi entitas. Normalisasi bertujuan untuk menyeragamkan format penulisan entitas yang mengacu pada objek yang sama tetapi ditulis dengan variasi berbeda, misalnya "Rasulullah SAW", "Nabi Muhammad", dan "Muhammad SAW" akan dipetakan ke bentuk kanonik yang sama. Hal ini penting untuk mencegah duplikasi node dalam knowledge graph dan memastikan konsistensi representasi pengetahuan. Deduplikasi kemudian menghapus entitas yang muncul berulang dalam satu chunk untuk menghindari redundansi data. Kedua proses ini memastikan kualitas hasil ekstraksi sebelum data digunakan untuk konstruksi graf atau analisis lebih lanjut.

Terakhir, pada baris 75–76, seluruh hasil ekstraksi yang telah dinormalisasi dan dideduplikasi disimpan dalam format CSV dengan nama file `entities_srl.csv`, kemudian dikembalikan sebagai output fungsi. File CSV ini berisi daftar lengkap entitas beserta metadata seperti chunk asal, tipe label, dan posisi teks, yang selanjutnya akan digunakan pada tahap pembentukan relasi dan *konstruksi knowledge graph*. Output terstruktur dalam format tabel memudahkan inspeksi manual, validasi kualitas ekstraksi, serta integrasi dengan sistem basis data graf.

3.3.2 Implementasi Pembentukan Knowledge Graph Menggunakan Neo4j

Kode Semu 3.2 di bawah ini menunjukkan alur kerja konstruksi *knowledge graph* di Neo4j.

INPUT	: entities_data (CSV berisi entitas)
	relations_data (CSV berisi relasi)
	db_name (nama database Neo4j)
OUTPUT	: Neo4j graph database

ALGORITMA:

```

1. BEGIN
2.   // Inisialisasi koneksi Neo4j
3.   driver ← Neo4jDriver.Connect(uri, username, password)
4.   session ← driver.Session(database=db_name)
5.
6.   // Buat constraint untuk mencegah duplikasi
7.   session.Run("CREATE CONSTRAINT person_name IF NOT EXISTS
8.               FOR (p:Person) REQUIRE p.name IS UNIQUE")
9.   session.Run("CREATE CONSTRAINT event_name IF NOT EXISTS
10.              FOR (e:Event) REQUIRE e.name IS UNIQUE")
11.  session.Run("CREATE CONSTRAINT location_name IF NOT EXISTS
12.              FOR (l:Location) REQUIRE l.name IS UNIQUE")
13.  session.Run("CREATE CONSTRAINT time_name IF NOT EXISTS
14.              FOR (t:Time) REQUIRE t.name IS UNIQUE")
15.
16.  // Import Node
17.  FOR EACH entity IN entities_data DO
18.    label ← CapitalizeFirst(entity.label)
19.    query ← "MERGE (n:" + label + " {name: $name})
20.            ON CREATE SET n.source_chunks = [$chunk_id]
21.            ON MATCH SET n.source_chunks = n.source_chunks + $chunk_id"
22.    session.Run(query, {
23.      name: NormalizeName(entity.entity_text),
24.      chunk_id: entity.chunk_id
25.    })
26.  END FOR
27.
28.  // Import Relationship
29.  FOR EACH relation IN relations_data DO
30.    source_label ← CapitalizeFirst(relation.source_label)
31.    target_label ← CapitalizeFirst(relation.target_label)
32.    rel_type ← relation.relation_type
33.
34.    query ← "MATCH (source:" + source_label + " {name: $source_name})
35.            MATCH (target:" + target_label + " {name: $target_name})
36.            MERGE (source)-[r:" + rel_type + "]->(target)
37.            ON CREATE SET r.evidence = [$evidence], r.chunk_ids =
[$chunk_id]
38.            ON MATCH SET r.evidence = r.evidence + $evidence,
39.            r.chunk_ids = r.chunk_ids + $chunk_id"
40.    session.Run(query, {
41.      source_name: NormalizeName(relation.source_text),
42.      target_name: NormalizeName(relation.target_text),
43.      evidence: relation.evidence,
44.      chunk_id: relation.chunk_id
45.    })
46.  END FOR
47.
48.  // Validasi graf
49.  Print("Node Person:", session.Run("MATCH (n:Person) RETURN count(n)"))
50.  Print("Node Event:", session.Run("MATCH (n:Event) RETURN count(n)"))
51.  Print("Node Location:", session.Run("MATCH (n:Location) RETURN count(n)"))
52.  Print("Node Time:", session.Run("MATCH (n:Time) RETURN count(n)"))
53.  Print("Rel INVOLVED_IN:", session.Run("MATCH ()-[r:INVOLVED_IN]->() RETURN
count(r)"))
54.  Print("Rel OCCURRED_AT:", session.Run("MATCH ()-[r:OCCURRED_AT]->() RETURN
count(r)"))

```



```

55.    Print("Rel OCCURRED_ON:", session.Run("MATCH ()-[r:OCCURRED_ON]->() RETURN
count(r)"))
56.
57.    session.Close()
58.    driver.Close()
59.    Print("Graph construction completed for database:", db_name)
60. END

```

Kode Semu 3.2 Alur Pembentukan Graph Database menggunakan Neo4j

Langkah pertama dimulai pada baris 2–4, yaitu melakukan inisialisasi koneksi ke database Neo4j. Sistem membuat driver koneksi dengan menyediakan URI server Neo4j, *username*, dan *password* yang diperlukan untuk autentikasi. Setelah koneksi berhasil dibuat, sistem membuka sesi kerja pada database yang telah ditentukan melalui parameter *db_name*. Sesi ini akan digunakan untuk menjalankan seluruh *query Cypher* yang diperlukan dalam proses konstruksi knowledge graph. Inisialisasi koneksi yang benar sangat penting untuk memastikan operasi basis data dapat berjalan dengan lancar dan aman.

Baris 7–14 bertujuan untuk membuat *constraint* (batasan integritas) pada setiap tipe node yang akan dibuat dalam graf. *Constraint* dibuat untuk masing-masing label node—*Person*, *Event*, *Location*, dan *Time*—dengan aturan bahwa properti *name* harus bersifat unik. Artinya, tidak boleh ada dua node dengan label yang sama dan nilai *name* yang identik. *Constraint* ini penting untuk mencegah duplikasi *node* dalam graf, misalnya mencegah pembuatan dua node *Person* dengan nama "Abu Bakar" yang seharusnya merepresentasikan tokoh yang sama. Klausula `IF NOT EXISTS` memastikan bahwa *constraint* hanya dibuat jika belum ada sebelumnya, sehingga proses dapat dijalankan berulang tanpa menimbulkan *error*. Selain mencegah duplikasi, *constraint* juga secara otomatis membuat index pada properti *name* yang mempercepat operasi pencarian *node*.

Selanjutnya, baris 17–26 melakukan proses *import node* (entitas) ke dalam database graf. Sistem melakukan iterasi pada setiap baris dalam file *entities_data* yang berisi daftar entitas hasil ekstraksi. Untuk setiap entitas, sistem mengambil label-nya (misalnya "*person*", "*event*"), mengubah huruf pertama menjadi kapital agar sesuai konvensi Neo4j (menjadi "*Person*", "*Event*"), kemudian membuat *query Cypher* menggunakan perintah `MERGE`. Perintah `MERGE` berfungsi ganda: jika *node* dengan nama tersebut belum ada, maka *node* baru akan dibuat dan properti *source_chunks* diinisialisasi dengan *chunk_id* asal; jika *node* sudah ada, maka *chunk_id* baru ditambahkan ke list *source_chunks* yang sudah ada. Pendekatan ini memungkinkan *tracking provenance*, yaitu mencatat semua sumber teks di mana entitas tersebut muncul. Contohnya, node `(:Person {name: "Abu Bakar", source_chunks: ["chunk_001", "chunk_015", "chunk_042"]})` menunjukkan bahwa tokoh Abu Bakar muncul di tiga chunk berbeda.

Baris 29–46 berfokus pada proses *import relationship* (relasi) antar-entitas. Sistem melakukan iterasi pada file *relations_data* yang berisi tripel relasi dalam format *source-relation-target*. Untuk setiap relasi, sistem terlebih dahulu mengidentifikasi tipe label *source* dan *target*, kemudian membuat *query Cypher* yang mencari kedua *node* yang terlibat menggunakan perintah `MATCH` berdasarkan nama *node*. Setelah kedua *node* ditemukan, perintah `MERGE` digunakan untuk membuat relasi di antara keduanya. Seperti pada *import node*, `MERGE` memastikan bahwa relasi tidak duplikat—jika relasi belum ada maka dibuat baru dengan properti *evidence* (potongan teks yang menjadi bukti relasi) dan *chunk_ids* (daftar chunk tempat relasi ditemukan); jika relasi sudah ada maka properti-properti tersebut diperbarui dengan

menambahkan data baru. Contoh relasi yang terbentuk: `(:Person {name: "Abu Bakar"})-[:INVOLVED_IN {evidence: "Abu Bakar ikut berperang di Badar", chunk_ids: ["chunk_042"]}]>(:Event {name: "Perang Badar"})`. Struktur ini memungkinkan penelusuran balik ke sumber teks untuk verifikasi atau analisis lebih lanjut.

Pada baris 49–55, dilakukan proses validasi graf untuk memastikan bahwa konstruksi *knowledge graph* telah berhasil dilakukan dengan benar. Sistem menjalankan serangkaian *query* sederhana untuk menghitung jumlah *node* per label dan jumlah *relationship* per tipe, kemudian menampilkan hasilnya. Misalnya, *query* `MATCH (n:Person) RETURN count(n)` menghitung total *node* bertipe *Person* yang ada dalam graf. Validasi ini penting untuk mendeteksi anomali seperti jumlah *node* atau relasi yang tidak sesuai ekspektasi, yang bisa mengindikasikan kegagalan dalam proses *import* atau masalah pada data sumber. Statistik yang ditampilkan juga memberikan gambaran umum tentang skala dan struktur graf yang telah dibangun, misalnya jumlah total tokoh, peristiwa, lokasi, waktu, serta keterhubungan di antara mereka.

Terakhir, pada baris 57–59, sistem menutup sesi kerja dan koneksi ke database Neo4j untuk membebaskan resource sistem. Pesan konfirmasi ditampilkan untuk menginformasikan bahwa proses konstruksi graf telah selesai dilakukan pada database yang ditentukan. Output akhir dari proses ini adalah sebuah *knowledge graph* yang tersimpan secara persisten dalam Neo4j, siap untuk diakses dan ditelusuri menggunakan *query Cypher*. Graf ini merepresentasikan struktur pengetahuan Sirah Nabawiyah dalam bentuk *node-node* entitas yang dihubungkan oleh *relationship* bermakna, memungkinkan eksplorasi informasi relasional seperti penelusuran tokoh yang terlibat dalam peristiwa tertentu, pemetaan peristiwa berdasarkan lokasi, atau pembentukan timeline kronologis peristiwa berdasarkan entitas waktu.

3.4 Urutan Pelaksanaan Penelitian

Penelitian Tugas Akhir ini akan dilaksanakan selama 16 Minggu dari Januari sampai dengan Mei 2026. Lini masa pengerjaan Tugas Akhir bisa dilihat pada Tabel 3.4.

Tabel 3.4 Lini Masa Pengerjaan Tugas Akhir

Deskripsi Kegiatan	Minggu ke-															
	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
Studi literatur	■	■	■													
Eksplorasi Program		■	■	■	■											
Preparasi Dataset dan Preprocessing data				■												
Implementasi Manual Labelling dan Pseudo-labelling				■	■	■	■									
Implementasi Pembentukan Relasi dan Konstruksi Graf						■	■	■	■							
Evaluasi Sistem						■	■	■	■	■						
Analisis Hasil dan Perbaikan								■	■	■	■					
Pelaporan Kemajuan		■		■		■		■		■		■		■		■
Penulisan laporan Tugas Akhir											■	■	■	■		
Revisi dan Finalisasi Laporan															■	■

DAFTAR PUSTAKA

- Abror, M., & Rahma, A. (2024). Sira Nabawiyya: Historiography of the Prophet Muhammad by Three Modern Writers. *Buletin Al-Turas*, 30(1), 25–38. <https://doi.org/10.15408/bat.v30i1.30008>
- Alam, M., Gangemi, A., Presutti, V., & Reforgiato Recupero, D. (2021). Semantic role labeling for knowledge graph extraction from text. *Progress in Artificial Intelligence*, 10(3), 309–320. <https://doi.org/10.1007/s13748-021-00241-7>
- Anuyah, S., Bolade, V., & Agbaakin, O. (2024). *Understanding Graph Databases: A Comprehensive Tutorial and Survey*. <http://arxiv.org/abs/2411.09999>
- Cai, B., Xiang, Y., Gao, L., Zhang, H., Li, Y., & Li, J. (2022). *Temporal Knowledge Graph Completion: A Survey*. <https://doi.org/10.24963/ijcai.2023/734>
- Chaudhary, S., Vyas, H., Arora, N., & D'Mello, S. (2024). Graph-based Named Entity Information Retrieval from News Articles using Neo4j. *2024 11th International Conference on Computing for Sustainable Global Development (INDIACom)*, 320–324. <https://doi.org/10.23919/INDIACom61295.2024.10499187>
- Chen, M., Zhang, W., Geng, Y., Xu, Z., Pan, J. Z., & Chen, H. (2023). *Generalizing to Unseen Elements: A Survey on Knowledge Extrapolation for Knowledge Graphs*.
- Choi, S., & Jung, Y. (2025). Knowledge Graph Construction: Extraction, Learning, and Evaluation. In *Applied Sciences (Switzerland)* (Vol. 15, Issue 7). Multidisciplinary Digital Publishing Institute (MDPI). <https://doi.org/10.3390/app15073727>
- Claudio M. (2025). PromptNER: An Automatic Prompt-Learning Data Labeling Approach for Named Entity Recognition on Sensitive Data. *Journal of Information and Data Management*, 16, 1. <https://doi.org/10.5753/jidm.2025.4298>
- Dagdelen, J., Dunn, A., Lee, S., Walker, N., Rosen, A. S., Ceder, G., Persson, K. A., & Jain, A. (2024). Structured information extraction from scientific text with large language models. *Nature Communications*, 15(1). <https://doi.org/10.1038/s41467-024-45563-x>
- Díaz, C., Dunstan, J., Etcheverry, L., Fonck, A., Grez, A., Mery, D., Reutter, J., & Rojas, H. (2024). *Automatic knowledge-graph creation from historical documents: The Chilean dictatorship as a case study*. <https://memoriaviva.com/nuevaweb/>
- Diaz-Garcia, J. A., & Lopez, J. A. D. (2025). A survey on cutting-edge relation extraction techniques based on language models. *Artificial Intelligence Review*, 58(9). <https://doi.org/10.1007/s10462-025-11280-0>
- Ding, L., Colavizza, G., & Zhang, Z. (2025). Partial Annotation Learning for Biomedical Entity Recognition. *IEEE Journal of Biomedical and Health Informatics*, 29(2), 1409–1418. <https://doi.org/10.1109/JBHI.2024.3466294>
- Du, Y. (2023). *The Construction of Knowledge Graph of Newspaper Distribution in Yan'an Period and Frontend Visualization* (pp. 776–789). https://doi.org/10.2991/978-2-38476-092-3_95

- Effland, T., & Collins, M. (2021). Partially Supervised Named Entity Recognition via the Expected Entity Ratio Loss. *Transactions of the Association for Computational Linguistics*, 9, 1320–1335. https://doi.org/10.1162/tacl_a_00429
- Ehrmann, M., Hamdi, A., Pontes, E. L., Romanello, M., & Doucet, A. (2024). Named Entity Recognition and Classification in Historical Documents: A Survey. *ACM Computing Surveys*, 56(2). <https://doi.org/10.1145/3604931>
- Francis, S. A., & Sangeetha, M. (2025). A comparison study on optical character recognition models in mathematical equations and in any language. *Results in Control and Optimization*, 18. <https://doi.org/10.1016/j.rico.2025.100532>
- Gana, B., Allende-Cid, H., Rüping, S., Becerra-Rozas, M., & Zamora, J. (2025). A systematic review of long document summarization methods: Evaluation metrics and approaches. In *Neurocomputing* (Vol. 655). Elsevier B.V. <https://doi.org/10.1016/j.neucom.2025.131287>
- Graciotti, A. (2023). *Knowledge Extraction from Multilingual and Historical Texts for Advanced Question Answering*. <https://doi.org/10.5281/zenodo.6772330>
- Hambarde, K. A., & Proenca, H. (2023). Information Retrieval: Recent Advances and beyond. *IEEE Access*, 11, 76581–76604. <https://doi.org/10.1109/ACCESS.2023.3295776>
- He, Y., Zhang, X., Oi, F., Xu, G., & Gui, G. (2022). Construction of Military Knowledge Graph Based on Neo4j and MongoDB. *2022 IEEE 8th International Conference on Computer and Communications, ICCC 2022*, 2043–2047. <https://doi.org/10.1109/ICCC56324.2022.10066012>
- Ji, S., Pan, S., Cambria, E., Marttinen, P., & Yu, P. S. (2021). *A Survey on Knowledge Graphs: Representation, Acquisition and Applications*. <https://doi.org/10.1109/TNNLS.2021.3070843>
- Jindal, I., Rademaker, A., Ulewicz, M., Ha, L., Nguyen, H., Tran, K.-N., Zhu, H., & Li, Y. (2022). *Universal Proposition Bank 2.0*. <https://github.com/System-T/>
- Kharis, M. A. (2024). AL-ISNAD: Journal of Indonesian Hadist Studies Volume 5 Nomor 2 Desember 2024 (76-88) COMPARATIVE STUDY BETWEEN HADĪTH AND SIRAH NABAWIYYAH REGARDING THE BIRTH OF THE PROPHET MUHAMMAD. In *Journal of Indonesian Hadist Studies* (Vol. 5, Issue 2).
- Kushavaha, K. (2024). OCR: Optical Character Recognition. *International Journal for Research in Applied Science and Engineering Technology*, 12(4), 3854–3856. <https://doi.org/10.22214/ijraset.2024.60794>
- Kusumah, M. W., Hidayat, T., Tamam, A. M., & Irwansyah, F. S. (2022). The Concept of Sirah Education Curriculum in Junior High School according to Abu Al-Hasan Ali Al-Nadwi. *Jurnal Kajian Peradaban Islam*, 6(1), 1–14. <https://doi.org/10.47076/jkpis.v6i1.154>
- Li, J., Sun, A., Han, J., & Li, C. (2022). A Survey on Deep Learning for Named Entity Recognition. In *IEEE TRANSACTIONS ON KNOWLEDGE AND DATA ENGINEERING* (Vol. 34, Issue 1). <https://www.mpi-inf.mpg.de/departments/>
- Li, J., Wang, Y., Zhang, S., & Zhang, M. (2023). *Rethinking Document-Level Relation Extraction: A Reality Check*.

- Lian, Z., Ma, Y., Li, M., Lu, W., & Zhou, W. (2024). Discovery Precision: An effective metric for evaluating performance of machine learning model for explorative materials discovery. *Computational Materials Science*, 233. <https://doi.org/10.1016/j.commatsci.2023.112738>
- Liu, L., Vlachidis, A., Crymble, A., Lee, D., & Humbel, M. (2025). Towards Comparable Historical NER: Building a Shared Evaluation Corpus for 18th-Century Historical Texts. *Anthology of Computers and the Humanities*, 3, 968–982. <https://doi.org/10.63744/dwcj80qvvatr>
- Paulheim, H. (2017). Knowledge graph refinement: A survey of approaches and evaluation methods. *Semantic Web*, 8(3), 489–508. <https://doi.org/10.3233/SW-160218>
- Powers, D. M. W. (2020). *EVALUATION: FROM PRECISION, RECALL AND F-MEASURE TO ROC, INFORMEDNESS, MARKEDNESS & CORRELATION*.
- Pratama, F. S. (2022). Analisis Komparatif Historiografi Sirah Nabawiyah Karya Ibnu Ishaq Dan Ibnu Hisyam. *Majalah Ilmiah Tabuah: Ta'limat, Budaya, Agama Dan Humaniora*, 26(1), 21–29. <https://doi.org/https://doi.org/10.37108/tabuah.v26i1.677>
- Prayogi, A., Yaqin, A., & Fuadi, M. Z. R. H. (2022). Descriptive Study of the Nabawiyah Sirah by Ibn Ishaq and Ibn Hisham. *International Journal of Islamic Thought and Humanities*, 1(2), 107–116. <https://doi.org/10.54298/ijith.v1i2.28>
- Ren, S., Wang, M., Zhang, J., & Ma, Z. (2024). A Knowledge Graph Construction Method for Complex Products Improvement Design. *ICNC-FSKD 2024 - 20th International Conference on Natural Computation, Fuzzy Systems and Knowledge Discovery*. <https://doi.org/10.1109/ICNC-FSKD64080.2024.10702222>
- Santana, B., Campos, R., Amorim, E., Jorge, A., Silvano, P., & Nunes, S. (2023). A survey on narrative extraction from textual data. *Artificial Intelligence Review*, 56(8), 8393–8435. <https://doi.org/10.1007/s10462-022-10338-7>
- Schäfer, H., Idrissi-Yaghir, A., Arzideh, K., Damm, H., Pakull, T. M. G., Schmidt, C. S., Bahn, M., Lodde, G., Livingstone, E., Schadendorf, D., Nensa, F., Horn, P. A., & Friedrich, C. M. (2024). BioKGrapher: Initial evaluation of automated knowledge graph construction from biomedical literature. *Computational and Structural Biotechnology Journal*, 24, 639–660. <https://doi.org/10.1016/j.csbj.2024.10.017>
- Solihin, F. (2022). *Relevansi dan Urgensi Aplikasi Metodologi Kritik Hadis Dalam Penelitian al-Sirah al-Nabawiyah*. <https://doi.org/https://doi.org/10.24252/tahdis.v12i2.20175>
- Song, M. (2026). Defining the problem: The impact of OCR quality on retrieval-augmented generation performance and strategies for improvement. *Information Processing and Management*, 63(1). <https://doi.org/10.1016/j.ipm.2025.104368>
- Viana da Silva, L., Lilles Jorge Drews Junior, P., & Silva da Costa Botelho, S. (2023). *An Optical Character Recognition Post-processing Method for technical documents*.
- Xie, Y., Jia, L., & Dai, J. (2023). Construction of a Traditional Chinese Medicine Dao Yin Science Knowledge Graph Based on Neo4j. *Proceedings - 2023 IEEE International Conference on Bioinformatics and Biomedicine, BIBM 2023*, 4662–4666. <https://doi.org/10.1109/BIBM58861.2023.10385657>

- Xu, D., Chen, W., Peng, W., Zhang, C., Xu, T., Zhao, X., Wu, X., Zheng, Y., Wang, Y., & Chen, E. (2024). Large language models for generative information extraction: a survey. In *Frontiers of Computer Science* (Vol. 18, Issue 6). Higher Education Press Limited Company. <https://doi.org/10.1007/s11704-024-40555-y>
- Yang, Y., Wu, Z., Yang, Y., Lian, S., Guo, F., & Wang, Z. (2022). A Survey of Information Extraction Based on Deep Learning. In *Applied Sciences (Switzerland)* (Vol. 12, Issue 19). MDPI. <https://doi.org/10.3390/app12199691>
- Zeynali Tazehkandi, M., & Nowkarizi, M. (2020). Three approaches to measuring recall on the Web: a systematic review. In *Electronic Library* (Vol. 38, Issue 3, pp. 477–492). Emerald Group Holdings Ltd. <https://doi.org/10.1108/EL-12-2019-0287>
- Zhao, X., Deng, Y., Yang, M., Wang, L., Zhang, R., Cheng, H., Lam, W., Shen, Y., & Xu, R. (2024). A Comprehensive Survey on Relation Extraction: Recent Advances and New Frontiers. *ACM Computing Surveys*, 56(11). <https://doi.org/10.1145/3674501>
- Zhong, L., Wu, J., Li, Q., Peng, H., & Wu, X. (2024). A Comprehensive Survey on Automatic Knowledge Graph Construction. *ACM Computing Surveys*, 56(4). <https://doi.org/10.1145/3618295>
- Zhou, S., Yu, B., Sun, A., Long, C., Li, J., & Sun, J. (2022). *A Survey on Neural Open Information Extraction: Current Status and Future Directions*.

LAMPIRAN